

Q&A chuẩn bị cho buổi bảo vệ

Mười câu hỏi khó nhất + cách trả lời

Nguyễn Trọng Bách — 23BI14057

Mục lục

Câu 1. Tại sao soft voting mà không stacking hay learned weights?

Câu hỏi

“Em chọn soft voting trung bình xác suất bốn mô hình. Sao không học trọng số ensemble (stacking, meta-learner)? Có thể tốt hơn không?”

Câu trả lời

Em đã cân nhắc cả ba phương án. Em chọn soft voting vì **ba lý do thực tế**:

Thứ nhất, stacking cần một validation set thứ hai để fit meta-learner — nếu dùng cùng val set đã chọn checkpoint thì meta-learner học *quirks* của val set chứ không phải tín hiệu thật, dẫn đến overfit. Tập ISIC 2018 đã nhỏ, lấy thêm một mảnh val đồng nghĩa lấy data train ra, không đáng đánh đổi.

Thứ hai, hard voting (argmax từng mô hình rồi vote) mất thông tin xác suất. Soft voting giữ trọn vector $p_m(x) \in [0, 1]^7$, cho phép ensemble phân biệt giữa “cả 4 mô hình rất chắc MEL” và “2 mô hình MEL 51%, 2 mô hình NV 49%”. Sự khác biệt này quan trọng lắm sòng.

Thứ ba, soft voting đã đạt 89.49% in-distribution và 90.49% với metadata. McNemar test cho thấy soft voting vượt mọi mô hình đơn với $p < 10^{-7}$ so với mô hình mạnh nhất. Không có *headroom* rõ ràng để stacking phá được, mà stacking lại tăng chi phí inference.

Mẹo trả lời

Nếu thầy/cô hỏi tiếp “vẫn nghĩ stacking sẽ tốt hơn” — đồng ý là có thể, nhưng nói rõ là “em đã ưu tiên tính tái lập và đơn giản với kết quả đã ngang SOTA, stacking là hướng tiếp theo nếu có thêm thời gian/data.”

Câu 2. Làm sao biết Grad-CAM là “đúng”?

Câu hỏi

“Heatmap đỏ vàng thì ai cũng thấy đẹp. Làm sao em biết mô hình thực sự nhìn vào tổn thương chứ không phải artifact trùng vị trí?”

Câu trả lời

Em không dừng ở định tính. Em đo **bốn chỉ số định lượng** so với mask lesion (sinh từ Otsu threshold) trên *toàn bộ test set*:

- **focus_ratio** — tỉ lệ tổng activation nằm trong mask lesion. Cao = focus đúng. Cả 4 mô hình đạt > 0.6 .
- **peak_distance** — khoảng cách từ peak activation tới centroid lesion (normalize theo đường chéo). Thấp = focus đúng tâm. Cả 4 mô hình đạt < 0.2 .
- **entropy** — Shannon entropy của heatmap. Thấp = focus sắc nét.
- **coverage_75** — % diện tích chứa top-25% activation. Thấp = compact.

Đây là cải tiến so với nhiều công trình chỉ show heatmap mà không định lượng. Bài học em rút ra từ chính việc này: lần đầu dùng `model.bn2` của EfficientNet, **focus_ratio** chỉ 0.18 — heatmap xanh đồng đều. Em chuyển sang `blocks[-1][-1]`, **focus_ratio** lên 0.51 — mới thực sự khoanh tổn thương. Nếu không có định lượng, sai lầm bn2 sẽ trượt qua.

Mẹo trả lời

Nhấn mạnh chuyện “định lượng phát hiện bug” — show được tư duy khoa học chứ không phải chỉ chạy code.

Câu 3. Macro F1 vs balanced accuracy khác gì? Tại sao chọn Macro F1?

Câu hỏi

“Em báo cáo Macro F1 chứ không phải balanced accuracy. Hai cái khác nhau thế nào? Tại sao chọn cái này?”

Câu trả lời

Balanced accuracy = trung bình recall theo lớp. Chỉ nhìn recall, bỏ qua precision.

Macro F1 = trung bình F1 theo lớp = trung bình điều hòa của precision và recall.

Khác biệt thực tiễn: balanced accuracy chỉ phạt mô hình *bỏ sót* (false negative). Macro F1 phạt cả *báo động giả* (false positive). Trên data mất cân bằng 58:1, mô hình có thể đạt balanced accuracy cao bằng cách dự đoán DF cho mọi ảnh mơ hồ — recall DF lên 100%, balanced accuracy tăng, nhưng precision DF sụp đổ. Macro F1 bắt được điều đó.

Em chọn Macro F1 vì trong lâm sàng *cả hai loại lỗi đều có chi phí*: bỏ sót MEL nguy hiểm, nhưng báo động giả cũng gây sinh thiết không cần thiết, tăng chi phí và stress cho bệnh nhân.

Trong báo cáo em vẫn đưa cả Sensitivity (= Recall) và Specificity (= $1 - \text{false positive rate}$) per-class để có bức tranh đầy đủ.

Câu 4. Tại sao Swin-Tiny overfit nhanh hơn các CNN?

Câu hỏi

“Swin-Tiny early-stop ở epoch 13 trong khi các CNN chạy tới 39–49. Em giải thích thế nào?”

Câu trả lời

Ba lý do cộng dồn:

(1) Thiếu inductive bias. CNN có sẵn translation invariance và locality vì kernel conv *có định kích thước*. Transformer học cả hai *từ data*, nên cần data nhiều hơn để hội tụ. ISIC 2018 chỉ 7.010 ảnh train — nhỏ so với chuẩn computer vision (ImageNet 1.28M).

(2) Tỷ lệ tham số/sample cực cao. Swin-Tiny 28M tham số / 7.010 ảnh = $4.000\times$. Cực kỳ dễ overfit. So với EB0 5.3M tham số = $756\times$, hợp lý hơn nhiều.

(3) Self-attention bậc 2. Mọi cặp patch đều attend lẫn nhau, dễ “ghi nhớ” cấu trúc không gian cụ thể của ảnh train.

Em đã cố giảm thiểu: learning rate thấp $1e-4$ (CNN dùng $3e-4$) để không phá pretrained attention weights, weight decay cao $5e-2$ (CNN dùng $1e-3$) để regularize mạnh, warmup 5 epoch (CNN 3 epoch). Early stop patience 12 bắt được checkpoint epoch 13.

Mặt tích cực: Swin trên đa hạt giống có **accuracy trung bình cao nhất** (88.33% so với EB0 87.31%) — early-stop sớm không có nghĩa là kém, chỉ là *phương sai cao hơn*. Trong ensemble, phương sai cao + lỗi không tương quan với CNN = thành phần có giá trị.

Câu 5. Nếu cho ảnh ngoài 7 lớp (vd. nốt mụn) thì sao?

Câu hỏi

“Em chỉ train 7 lớp. Nếu bệnh nhân chụp ảnh mụn trứng cá, vết sẹo — mô hình sẽ làm gì?”

Câu trả lời

Mô hình **buộc phải gán** một trong 7 lớp với softmax tổng bằng 1 — không có lớp “other”. Đây là điểm yếu thật sự của mọi classifier closed-set.

Hai giải pháp em đã tích hợp:

Confidence threshold. App Streamlit đặt ngưỡng 50%; nếu top-1 dưới 50% sẽ hiển thị cảnh báo “Low confidence” và đề xuất hỏi chuyên gia. Trong test set ISIC, tỉ lệ low-conf chỉ ~2%, nên cảnh báo không spam người dùng.

Predictive entropy. App cũng tính entropy của vector xác suất. Entropy cao (gần $\log 7$) = mô hình không chắc giữa nhiều lớp = có thể là OOD. Em hiển thị entropy số trong app.

Giải pháp đầy đủ hơn cho production: *open-set classifier* hoặc *OOD detector* riêng (ví dụ Mahalanobis distance trên features, hoặc Energy-based score). Em chưa triển khai vì đây là prototype — đó là hướng phát triển hiển nhiên tiếp theo.

Mẹo trả lời

Đây là điểm **thầy cô YT/AI sẽ rất quan tâm**. Nói thẳng “mô hình không biết khi không biết” — thừa nhận điểm yếu rồi nêu giải pháp. Nếu nói “mô hình sẽ phân loại đúng lớp gần nhất” là sai.

Câu 6. Bao nhiêu false negative MEL trong test? Tác động lâm sàng?

Câu hỏi

“Em báo F1 melanoma 0.744. Cụ thể, trong 167 ảnh MEL test, mô hình bỏ sót bao nhiêu? Hậu quả lâm sàng?”

Câu trả lời

Số liệu trên test set ISIC 2018:

- Test set có 167 ảnh MEL thật.
- Ensemble nhận đúng 124 ca → **43 false negative** (recall 0.740).
- Trong 43 ca bỏ sót: 35 ca model gán nhầm là NV (nốt ruồi lành), 8 ca BKL.

Tác động lâm sàng nếu deploy nguyên trạng: với 100 bệnh nhân MEL thật đến khám, 74 được phát hiện đúng, 26 bị gán “lành tính” và có nguy cơ rời phòng khám mà không được sinh thiết. Đây là lý do prototype Streamlit **không bao giờ** thay thế chẩn đoán bác sĩ — chỉ là second opinion.

Đã có hướng giảm: threshold tuning với Youden’s J (slide A18) hạ ngưỡng MEL từ 0.143 (mặc định) xuống 0.100 đẩy MEL Sensitivity từ 0.74 lên 0.83 — bỏ sót giảm còn 17/100 thay vì 26/100. Đổi lại tăng false positive (specificity giảm từ 0.97 xuống 0.95 — chấp nhận được trong lâm sàng vì bỏ sót MEL nguy hiểm hơn báo động giả nhiều).