

Đánh giá So sánh các Mô hình Học sâu cho Bài toán Phân loại Tổn thương Da trên Ảnh Dermoscopy

Tiếp cận Ensemble và Khả diễn giải bằng Grad-CAM

Nguyễn Trọng Bách — 23BI14057

GVHD nội bộ: TS. Nghiêm Thị Phương **GVHD bên ngoài:** TS. Vũ Trọng Sinh

Khoa Công nghệ Thông tin và Truyền thông
Đại học Khoa học và Công nghệ Hà Nội

Tháng 7, 2026



Nội dung trình bày

- 1 Giới thiệu
- 2 Dữ liệu và thách thức
- 3 Phương pháp
- 4 Kết quả thực nghiệm
- 5 Nghiên cứu loại bỏ thành phần
- 6 Khả diễn giải và ứng dụng
- 7 Kết luận

Trọng tâm khóa luận


Xây dựng và đánh giá một pipeline học sâu hoàn chỉnh cho phân loại 7 lớp tổn thương da trên ISIC 2018, kết hợp **4 kiến trúc** bằng **soft-voting ensemble** và diễn giải kết quả bằng **Grad-CAM**.

Vấn đề lâm sàng

Ung thư hắc tố chiếm phần lớn số tử vong do ung thư da, nhưng tỷ lệ sống sau 5 năm vượt **99%** nếu phát hiện sớm. Dermoscopy giúp quan sát tổn thương ở mức không xâm lấn, song việc diễn giải phụ thuộc nặng vào kinh nghiệm bác sĩ.

Ba trở ngại của AI hỗ trợ chẩn đoán:

- ▶ **Mất cân bằng dữ liệu** — lớp đa số áp đảo các lớp ác tính hiếm.
- ▶ **Tương đồng hình thái** — Melanoma và Nevus dễ nhầm lẫn.
- ▶ **Hộp đen** — bác sĩ khó tin cậy nếu không có giải thích.



Hình: Phân bố 7 lớp trong ISIC 2018 — tỉ lệ NV:DF lên tới 58:1.

Mục tiêu chính

Xây dựng pipeline tự động phân loại **7 loại tổn thương da** từ ảnh dermoscopy, đạt độ chính xác cao đồng thời **khả diễn giải** cho mục đích lâm sàng.

Bốn đóng góp cụ thể

- ➊ Pipeline xử lý mất cân bằng bằng Weighted Sampler, Mixup, CutMix, Label Smoothing.
- ➋ So sánh **4 kiến trúc** (CNN + Transformer) trên cùng một pipeline.
- ➌ **Soft-voting ensemble** đẩy hiệu năng vượt mô hình đơn.
- ➍ **Grad-CAM** cùng prototype Streamlit để bác sĩ kiểm tra trực quan.

Kim chỉ nam: ưu tiên *Macro F1* và *Macro AUC* — không để Accuracy lừa.

HAM10000 — chuẩn benchmark dermoscopy:

- ▶ 10.015 ảnh, 7 lớp tổn thương.
- ▶ Chia theo *stratified sampling* 70/15/15.
- ▶ Mỗi split giữ nguyên tỉ lệ 7 lớp.

Chỉ số ưu tiên

Vì lớp NV chiếm 67% nên Accuracy không phản ánh đúng. Ta đo bằng **Macro F1** và **Macro AUC** — bình đẳng với mọi lớp.

Lớp	Train	Val	Test	Tổng	%
NV (Nevus)	4 693	1 006	1 006	6 705	66.9
MEL (Melanoma)	779	167	167	1 113	11.1
BKL (Benign Ker.)	769	165	165	1 099	11.0
BCC (Basal Cell)	360	77	77	514	5.1
AKIEC (Actinic)	229	49	49	327	3.3
VASC (Vascular)	99	21	22	142	1.4
DF (Dermatofibroma)	81	17	17	115	1.1
Tổng	7 010	1 502	1 503	10 015	100

Tỉ lệ mất cân bằng cực đoan: **NV : DF $\approx$ 58 : 1**

Hệ quả của mất cân bằng dữ liệu


Tại sao mất cân bằng là vấn đề nghiêm trọng?

- ▶ Mạng nơ-ron tối thiểu hóa loss tổng thể $\Rightarrow$ ưu tiên lớp đa số.
- ▶ Dự đoán "NV cho mọi ảnh" vẫn cho $\sim 67\%$ Accuracy — nhưng vô dụng lâm sàng.
- ▶ Lớp DF, VASC, AKIEC có < 250 ảnh huấn luyện — rất dễ *memorize* thay vì học features.

Bốn cơ chế đối phó trong pipeline


- 1 **Weighted Random Sampler** cân bằng mini-batch.
- 2 **Mixup / CutMix** làm mịn ranh giới quyết định.
- 3 **Label Smoothing** chống over-confidence.
- 4 **Macro F1** làm tiêu chí chọn checkpoint.

Transfer Learning and Fine-tuning



Hình: Transfer learning từ ImageNet sang ISIC: tái sử dụng features tổng quát, chỉ thay classifier head.

Pipeline tổng quan



Bốn kiến trúc được so sánh

Mô hình	Tham số	Nguyên tắc thiết kế	Vai trò trong ensemble
EfficientNet-B0	5.3M	MBConv + SE, compound scaling	CNN gọn, đặc trưng local mịn
ResNet50	25.6M	Bottleneck residual	CNN sâu, baseline cổ điển
DenseNet121	8.0M	Dense connectivity, tái sử dụng features	CNN tận dụng feature reuse
Swin-Tiny	28.0M	Shifted-window self-attention	Vision Transformer, ngữ cảnh toàn cục

- ▶ Tất cả mô hình **fine-tune từ ImageNet pretrained** qua thư viện `timm`.
- ▶ Đầu ra thay bằng `Linear( $d$ , 7)`, dropout 0.25–0.30 trước classifier.
- ▶ Lựa chọn 4 kiến trúc đa dạng để ensemble khai thác **lỗi không tương quan** giữa CNN và Transformer.

Chiến lược huấn luyện

Mixup & CutMix ($p = 0.5$ mỗi loại)

Mixup: $\tilde{x} = \lambda x_i + (1 - \lambda) x_j$ với $\lambda \sim \text{Beta}(0.2, 0.2)$.

CutMix: dán patch ngẫu nhiên giữa hai ảnh, nhân lai theo tỉ lệ diện tích.

⇒ ngăn memorize sample hiếm, làm mịn ranh giới quyết định.

Weighted Random Sampler

Trọng số mỗi mẫu: $w_c = \frac{N}{C \cdot n_c}$

Mỗi batch xấp xỉ cân bằng 7 lớp — tăng exposure cho DF/VASC.

Label Smoothing ($\varepsilon = 0.1$)

$y_{\text{smooth}} = (1 - \varepsilon) \cdot y_{\text{onehot}} + \varepsilon / C$

⇒ giảm over-confidence, cải thiện calibration.

Cấu hình tối ưu

Optimizer: AdamW, cosine annealing + linear warmup.

Mixed precision: FP16 (giảm ~40% bộ nhớ GPU).

Gradient clipping: $\|\nabla\|_{\max} = 1.0$.

Early stopping: patience = 12 epoch theo Macro F1.

Siêu tham số theo mô hình

Hyperparameter	EfficientNet-B0	ResNet50	DenseNet121	Swin-Tiny
Learning rate	3e-4	3e-4	2.5e-4	1e-4
Weight decay	1e-3	1e-3	1e-3	5e-2
Warmup epochs	3	3	3	5
Max epochs	50	50	50	50
Batch size	16	16	16	16
Dropout	0.30	0.30	0.25	0.30
Mixup / CutMix α	0.2 / 1.0	0.2 / 1.0	0.2 / 1.0	0.2 / 1.0
Label smoothing ϵ	0.1	0.1	0.1	0.1

Swin-Tiny tại sao khác biệt?

Transformer thiếu *inductive bias* của CNN $\Rightarrow$ cần **learning rate thấp** (1e-4) để không phá vỡ attention weights pretrained, và **weight decay cao** (5e-2) để hạn chế overfit trên dataset nhỏ.

Hiệu năng từng mô hình đơn

Mô hình	Params	Epoch tốt nhất	Accuracy	Macro F1	AUC	Kappa
EfficientNet-B0	5.3M	39	0.8836	0.8311	0.9522	0.7710
ResNet50	25.6M	39	0.8603	0.7902	0.9565	0.7309
DenseNet121	8.0M	49	0.8543	0.7967	0.9587	0.7206
Swin-Tiny	28.0M	13	0.8490	0.7855	0.9600	0.7150

EfficientNet-B0 — quán quân đơn lẻ

Ít tham số nhất (5.3M) mà Accuracy và Macro F1 cao nhất. Compound scaling cộng với SE-blocks rất hợp với ảnh dermoscopy 224×224 .

Swin-Tiny — paradox calibration

Overfit sớm nhất (epoch 13) nhưng AUC cao nhất 0.960. Cho thấy Swin xếp hạng xác suất tốt, nhưng quyết định cứng (argmax) thì kém hơn CNN.

Ensemble: kết hợp 4 mô hình bằng soft voting

Cơ chế: trung bình các vector xác suất đầu ra.


$$\bar{p}(x) = \frac{1}{M} \sum_{m=1}^M p_m(x), \quad M = 4$$

- ▶ CNN bắt features cục bộ, Swin bắt ngữ cảnh toàn cục $\Rightarrow$ lỗi không tương quan.
- ▶ Trung bình xác suất **giảm phương sai dự đoán**.
- ▶ Không cần huấn luyện thêm, chỉ inference 4 lần.

Kết quả Ensemble (test set 1 503 ảnh)

1 hạt giống: Acc **89.49%** F1 **0.845** AUC **0.980**

5 hạt giống: $89.93 \pm 0.66\%$ 0.852 ± 0.010 0.982 ± 0.001



Hình: Kiến trúc soft-voting ensemble: 4 mô hình cùng inference, xác suất được trung bình trước khi argmax.

Phân tích chi tiết theo lớp (EB0 vs. Ensemble)


Lớp	F1 theo lớp			AUC theo lớp		
	EB0	Ensemble	Δ	EB0	Ensemble	Δ
AKIEC	0.717	0.710	-0.007	0.921	0.972	+0.051
BCC	0.865	0.825	-0.040	0.984	0.996	+0.012
BKL	0.758	0.796	+0.038	0.938	0.968	+0.030
DF	0.938	0.938	0.000	0.963	0.996	+0.033
MEL	0.695	0.744	+0.049	0.913	0.958	+0.045
NV	0.940	0.946	+0.006	0.946	0.972	+0.026
VASC	0.905	0.955	+0.050	1.000	1.000	0.000

- ▶ **Melanoma cải thiện rõ rệt** — lớp lâm sàng quan trọng nhất, F1 tăng +4.9%, AUC tăng +4.5%.
- ▶ **AUC tăng đồng đều** trên cả 7 lớp $\Rightarrow$ ensemble là công cụ *xếp hạng rủi ro* mạnh.
- ▶ BCC giảm nhẹ F1 do Swin overconfident; bù lại AUC vẫn rất cao 0.996.

Ma trận nhầm lẫn của Ensemble

Đọc ma trận:

- ▶ Đường chéo cao $\Rightarrow$ recall tốt trên mọi lớp.
- ▶ **DF**, **VASC** hiếm nhưng vẫn được nhận diện chính xác — nhờ Mixup + Weighted Sampler.
- ▶ Nhầm lẫn còn lại tập trung ở cụm **MEL** $\leftrightarrow$ **NV** $\leftrightarrow$ **BKL**, vốn tương đồng hình thái.
- ▶ Không có lớp nào bị "biến mất" — tránh được lỗi điển hình của mất cân bằng.



Ablation Study — đóng góp của từng thành phần

Cùng EfficientNet-B0, lần lượt loại bỏ một thành phần để đo mức suy giảm Macro F1.

Cấu hình	Accuracy	Macro F1	AUC	Δ Macro F1
Full pipeline (baseline)	0.8836	0.8311	0.9522	–
– Mixup & CutMix	0.8589	0.7860	0.9486	–0.0451
– Label Smoothing	0.8776	0.8000	0.9674	–0.0311
– Weighted Sampler	0.8762	0.8041	0.9521	–0.0270
– Advanced Augmentation	0.8896	0.8204	0.9664	–0.0107

- ▶ Mỗi thành phần đều có đóng góp dương lên **Macro F1** — không có module thừa.
- ▶ Hai hàng cuối thú vị: bỏ Label Smoothing tăng AUC, bỏ Aug mạnh tăng Accuracy — chính là các **trade-off thiết kế**.

Diễn giải kết quả Ablation

1. Mixup/CutMix — thành phần quan trọng nhất (−4.51% F1)

Với chỉ 81 ảnh DF và 99 ảnh VASC trong train set, không có Mixup/CutMix mô hình sẽ *memorize* sample hiếm sau vài epoch. Ảnh lại buộc model học features tổng quát, không gán xác suất 1.0 cho bất kỳ ảnh đơn lẻ nào.

2. Nghịch lý Label Smoothing — AUC tăng nhưng F1 giảm

Bỏ Label Smoothing **tăng AUC** (0.952 → 0.967) nhưng **giảm F1** 3.11%. Hard target khiến model tự tin hơn (xếp hạng tốt ⇒ AUC cao), nhưng ranh giới quyết định cứng làm sai nhiều ở cụm MEL/NV/BKL.


3. Trade-off Augmentation — Accuracy tăng, Macro F1 giảm

Bỏ aug mạnh, Accuracy thậm chí **nhỉnh hơn baseline** (88.96% vs 88.36%) vì model dễ học lớp NV. Nhưng Macro F1 giảm — minority class bị bỏ rơi. Đây là lý do *không dùng Accuracy làm tiêu chí chính*.

Grad-CAM — nhìn vào “lý do” mô hình quyết định

Quy trình Grad-CAM:

- 1 Hook activation A^k và gradient $\partial y_c / \partial A^k$ tại layer conv cuối.
- 2 Trọng số $\alpha_c^k = \text{GAP}(\nabla A^k)$.
- 3 Heatmap: $L_c = \text{ReLU}(\sum_k \alpha_c^k A^k)$.
- 4 Up-sample về kích thước ảnh gốc và overlay.



Hình: Grad-CAM trên một mẫu Melanoma: cả 4 mô hình tập trung vào ổ sắc tố trung tâm.

Phát hiện thực nghiệm

Heatmap khoanh **đúng vùng tổn thương** trên cả 4 mô hình, vững trước nhiễu (lông, bọt gel, viền tối) — cơ sở để bác sĩ tin cậy hệ thống.

Prototype Streamlit — “second opinion” thời gian thực

Tính năng chính:

- ▶ Upload ảnh $\Rightarrow$ inference ensemble trong <2 giây.
- ▶ Hiển thị **phân bố xác suất 7 lớp**, không chỉ nhãn cứng.
- ▶ Cho phép chọn mô hình bất kỳ để xem Grad-CAM riêng.
- ▶ **Subprocess isolation** (`gradcam_worker.py`) ngăn rò GPU memory khi chạy liên tục.

Giá trị lâm sàng

Hệ thống đóng vai trò *second opinion* cho bác sĩ: cung cấp **xác suất** + **bằng chứng trực quan**, không thay thế chẩn đoán mà hỗ trợ quyết định.

Có thể demo trực tiếp

```
streamlit run app.py  
→ http://localhost:8501
```

Sáu đóng góp chính của khóa luận

- 1 **Ensemble chỉ-ảnh: 89.49% Acc, 0.980 AUC, 0.744 F1** cho Melanoma ở hạt giống đại diện; **$89.93 \pm 0.66\%$** qua 5 hạt giống.
- 2 **Robustness thống kê:** McNemar xác nhận ensemble vượt mọi backbone với $p < 10^{-7}$ so với mạnh nhất, $p < 10^{-38}$ so với yếu nhất.
- 3 **Metadata fusion vượt 90%:** thêm metadata bệnh nhân HAM10000 đạt **90.49% / 0.873 F1** — vượt Pacheco & Krohling 2020.
- 4 **Đánh giá OOD trung thực:** zero-shot trên PAD-UFES-20 (ảnh smartphone) đạt 32.5% — định lượng khoảng cách modality.
- 5 **Khả năng giải định lượng:** Grad-CAM `focus_ratio > 0.6` trên cả 4 backbone, được validate qua `story debug model.bn2`.
- 6 **Ứng dụng thực tế:** prototype Streamlit ổn định với subprocess-isolated Grad-CAM.

Thông điệp: Pipeline được điều chỉnh cẩn thận có thể thu hẹp phần lớn khoảng cách giữa mô hình nhẹ và mô hình lớn trên dữ liệu y tế hạn chế.

- 1 **Domain adaptation cho ảnh smartphone:** kết quả OOD trên PAD-UFES-20 (phụ lục A23) cho thấy drop —56 pp accuracy. Đóng khoảng cách cần fine-tune trên data in-domain hoặc style-transfer preprocessing.
- 2 **Open-set / OOD detection:** classifier hiện tại bị buộc gán 1 trong 7 lớp. Production cần component nhận diện input *không phải* tổn thương da (mụn, sẹo, ảnh sai vùng).
- 3 **Active learning loop:** cho phép bác sĩ chỉnh sửa nhãn sai trong prototype, định kỳ retrain mô hình.
- 4 **Calibration sâu hơn:** áp dụng temperature scaling, focal loss để mô hình "tự biết khi nó không biết".
- 5 **Triển khai biên (edge):** chuyển ensemble sang ONNX/TensorRT, hướng tới chạy trên thiết bị dermoscopy di động.

Cảm ơn các thầy cô đã lắng nghe!

Em xin sẵn sàng đón nhận các câu hỏi

Demo trực tiếp prototype Streamlit có thể được trình diễn theo yêu cầu.



Phụ lục

Kiến thức nền tảng & chi tiết kỹ thuật

Các slide tham chiếu cho phần hỏi đáp.

- ❶ Chi tiết 7 lớp tổn thương da
- ❷ Pretrain vs. Fine-tune
- ❸ Toán học Mixup & CutMix
- ❹ Label Smoothing — chứng minh và trực giác
- ❺ Weighted Random Sampler — công thức
- ❻ Augmentation pipeline đầy đủ
- ❼ Toán học Grad-CAM
- ❽ Target layer Grad-CAM theo mô hình
- ❾ Grad-CAM định lượng (focus ratio, entropy)
- ❿ Tại sao Soft Voting hiệu quả
- ⓫ Định nghĩa toàn bộ chỉ số đánh giá
- ⓬ Bảng kết quả per-class đầy đủ
- ⓭ Lịch sử huấn luyện và overfit
- ⓮ Tại sao Swin overfit sớm
- ⓯ Cụm nhầm lẫn MEL $\leftrightarrow$ NV $\leftrightarrow$ BKL
- ⓰ Calibration và Temperature Scaling
- ⓱ Test-Time Augmentation (TTA)
- ⓲ Threshold Tuning
- ⓳ So sánh với SOTA trên ISIC 2018
- ⓴ Hạn chế & rủi ro lâm sàng

A1. Chi tiết 7 lớp tổn thương da

Mã	Tên đầy đủ	Đặc điểm lâm sàng
AKIEC	Actinic Keratosis / Bowen's	Tiền ung thư, do tia UV, có thể tiến triển thành SCC.
BCC	Basal Cell Carcinoma	Ung thư phổ biến nhất, hiếm di căn, cần phẫu thuật.
BKL	Benign Keratosis	Lành tính nhưng dễ nhầm với MEL/BCC trên dermoscopy.
DF	Dermatofibroma	U xơ lành tính, hiếm gặp (1.1%).
MEL	Melanoma	Ác tính, di căn nhanh, mục tiêu phát hiện hàng đầu.
NV	Melanocytic Nevus	Nốt ruồi sắc tố lành tính, chiếm đa số.
VASC	Vascular Lesion	Tổn thương mạch máu (angioma, hemorrhage).

Trong lâm sàng, hai mục tiêu ưu tiên là: (1) phát hiện sớm MEL và (2) phân biệt BCC khỏi tổn thương lành.

A2. Pretrain vs. Fine-tune — vì sao transfer learning hiệu quả

	Train từ đầu	Fine-tune
Dữ liệu cần	> 100 000 ảnh	vài nghìn ảnh
Thời gian	Hàng tuần	Vài chục phút
Kết quả trên data nhỏ	Kém (overfit nặng)	Tốt hơn rõ rệt
Lý do	Học features từ scratch	Tái sử dụng features ImageNet

Trong project:

- ▶ Tải pretrained weights từ `timm` (ImageNet-1K, 1.28M ảnh).
- ▶ Thay classifier: `Linear(d, 1000) → Linear(d, 7)`.
- ▶ Fine-tune *toàn bộ* mô hình với LR nhỏ + warmup để không phá hỏng features pretrained.

A3. Toán học Mixup & CutMix

Mixup — Zhang et al., ICLR 2018

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j, \quad \lambda \sim \text{Beta}(\alpha, \alpha), \quad \alpha = 0.2$$

$\alpha = 0.2$ làm λ thiên về 0 hoặc 1 $\Rightarrow$ pha trộn nhẹ, không phá ảnh quá mức.

CutMix — Yun et al., ICCV 2019

$$\tilde{x} = M \odot x_i + (1 - M) \odot x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j$$

M là mask bounding box ngẫu nhiên với diện tích tỉ lệ $1 - \lambda$.

$\alpha = 1.0 \Rightarrow \lambda$ uniform $[0, 1]$, kích cỡ patch đa dạng.

Trực giác

Mixup ép mô hình hoạt động *tuyến tính* giữa các mẫu huấn luyện. CutMix giữ pixel gốc nguyên vẹn (tốt cho features cục bộ) mà vẫn buộc mô hình nhìn nhiều vùng. Hai phương pháp **bổ trợ nhau**, áp dụng với xác suất 0.5 mỗi loại.

A4. Label Smoothing — chứng minh và trực giác

Định nghĩa:

$$y_k^{\text{LS}} = (1 - \varepsilon) \mathbb{I}[k = c] + \frac{\varepsilon}{C}, \quad \varepsilon = 0.1, C = 7$$

Ví dụ với lớp đúng là MEL:

$$y^{\text{onehot}} = [0, 0, 0, 0, 1, 0, 0] \rightarrow y^{\text{LS}} = [0.014, 0.014, 0.014, 0.014, 0.914, 0.014, 0.014]$$

Tại sao có hiệu quả?

- ▶ Loss cross-entropy với hard target khuyến khích logit của lớp đúng $\rightarrow +\infty \Rightarrow$ over-confidence.
- ▶ Smoothing đặt cận trên cho logit "đúng", các logit "sai" cũng không bị đẩy về $-\infty$.
- ▶ Hệ quả: ranh giới quyết định *mềm hơn* $\Rightarrow$ tổng quát hóa tốt hơn ở vùng biên giữa các lớp tương đồng.

Ngịch lý đã quan sát: bỏ LS thì AUC tăng (xếp hạng probability sắc nét hơn) nhưng F1 giảm (sai ở vùng biên).

A5. Weighted Random Sampler — công thức

Trọng số mỗi mẫu:

$$w_i = \frac{N}{C \cdot n_{c(i)}}$$

với N = tổng số mẫu train, $C = 7$, n_c = số mẫu lớp c , $c(i)$ = nhãn của mẫu i .

Trọng số 7 lớp trong ISIC 2018 (train split):

Lớp	n_c	$w_c = N / (C \cdot n_c)$
NV	4 693	0.213
MEL	779	1.286
BKL	769	1.303
BCC	360	2.782
AKIEC	229	4.373
VASC	99	10.117
DF	81	12.365

Tác động: mỗi mini-batch xấp xỉ cân bằng 7 lớp $\Rightarrow$ DF được nhìn thấy $\sim 58\times$ thường xuyên hơn so với sampling tự nhiên.

A6. Augmentation pipeline đầy đủ

Phép biến đổi	Train	Eval
Resize 224×224	✓	✓
RandomResizedCrop (scale 0.85–1.0)	✓	—
HorizontalFlip ($p = 0.5$)	✓	—
VerticalFlip ($p = 0.5$)	✓	—
Rotation $\pm 90^\circ$	✓	—
ColorJitter (brightness/contrast/sat/hue = 0.25)	✓	—
GaussianBlur ($p = 0.1$)	✓	—
RandomErasing ($p = 0.1$)	✓	—
Normalize (mean/std ImageNet)	✓	✓
Mixup ($\alpha = 0.2$) / CutMix ($\alpha = 1.0$), $p = 0.5$ mỗi loại	✓	—

Eval transform tối giản — chỉ resize + normalize — để đảm bảo so sánh công bằng giữa train (đa dạng) và test (chuẩn).

A7. Toán học Grad-CAM (Selvaraju et al., 2017)

Cho ảnh vào x , lớp mục tiêu c , layer convolution $A \in \mathbb{R}^{K \times H \times W}$:

Bước 1 — forward + backward:

$$y^c = f_\theta(x)[c], \quad \frac{\partial y^c}{\partial A_{ij}^k} \quad (\text{lấy qua hook})$$

Bước 2 — trọng số kênh (global average pooling gradient):

$$\alpha_c^k = \frac{1}{HW} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}$$

Bước 3 — heatmap (chỉ giữ phần positive):

$$L_c = \text{ReLU} \left(\sum_k \alpha_c^k A^k \right)$$

Bước 4: up-sample L_c về 224×224 , chuẩn hóa $[0, 1]$, overlay lên ảnh gốc bằng colormap JET.

Thực tế: α_c^k đo "kênh nào đóng góp dương cho lớp c "; tổng có trọng số cho biết vị trí nào trên ảnh là bằng chứng cho lớp đó.

A8. Target layer Grad-CAM theo từng mô hình

Mô hình	Target layer	Kích thước	Lý do
EfficientNet-B0	<code>model.blocks[-1][-1]</code>	(320, 7, 7)	MBConv cuối, có depthwise 3×3
ResNet50	<code>model.layer4[-1]</code>	(2048, 7, 7)	Residual block cuối
DenseNet121	<code>model.features.norm5</code>	(1024, 7, 7)	BatchNorm sau dense block cuối
Swin-Tiny	<code>model.layers[-1].blocks[-1].norm2</code>	(49, 768)	LayerNorm sau attention block cuối

Bài học sai lầm thường gặp — `model.bn2` của EfficientNet

Ban đầu dùng `model.bn2` (BatchNormAct2d + SiLU). Do $\text{SiLU}(x) \approx 0$ với $x < 0$, sau BN $\sim 50\%$ activation về 0 $\Rightarrow$ chỉ 18% pixel có activation $\Rightarrow$ heatmap xanh đồng đều, không tập trung.

Chuyển sang `blocks[-1][-1]`: 51% pixel active, kết quả khoanh đúng tổn thương.

A9. Grad-CAM định lượng

Để chứng minh Grad-CAM *thực sự* khoanh đúng tổn thương (không chỉ "trông đẹp"), ta đo các chỉ số sau trên mỗi heatmap (so với mask lesion sinh từ Otsu threshold):

Chỉ số	Ý nghĩa
<code>focus_ratio</code>	Tỉ lệ tổng activation nằm trong lesion mask. Cao $\Rightarrow$ focus đúng chỗ.
<code>mean_activation_in/out</code>	Cường độ trung bình bên trong / bên ngoài lesion mask.
<code>entropy</code>	Shannon entropy của heatmap. Thấp $\Rightarrow$ focus sắc nét.
<code>peak_distance</code>	Khoảng cách từ peak activation tới centroid lesion (normalize theo đường chéo).
<code>coverage_75</code>	Phần trăm diện tích chứa 25% activation cao nhất. Thấp $\Rightarrow$ tập trung.

Cả 4 mô hình trong project đều có `focus_ratio` > 0.6 và `peak_distance` < 0.2 trên tập test — bằng chứng định lượng rằng mô hình *nhìn đúng*.

A10. Tại sao Soft Voting hiệu quả?

Định lý phân rã bias–variance (Brown et al., 2005): sai số ensemble =

$$\underbrace{\overline{\text{bias}^2}}_{\text{trung bình của bias}} + \underbrace{\frac{1}{M} \overline{\text{var}}}_{\text{variance giảm } M \text{ lần (nếu độc lập)}} + \underbrace{\frac{M-1}{M} \overline{\text{cov}}}_{\text{covariance dư}}$$

Trong ensemble của ta:

- ▶ **Bias** của mỗi mô hình tương đương (cùng task, cùng data) $\Rightarrow$ trung bình bias không đổi.
- ▶ **Variance** giảm theo $1/M$ nếu các mô hình lỗi độc lập.
- ▶ **Key:** CNN (local receptive field) và Swin (global self-attention) có **lỗi không tương quan** $\Rightarrow$ covariance thấp $\Rightarrow$ ensemble cải thiện thật sự.

Phương án xem xét nhưng bị loại

Hard voting (argmax từng mô hình rồi vote) — mất thông tin xác suất, hiệu suất thấp hơn 1.5%.

Stacking (meta-learner học trọng số ensemble) — cần validation set riêng, gây overfit với dataset nhỏ.

A11. Định nghĩa các chỉ số đánh giá

Chỉ số	Công thức	Ý nghĩa
Accuracy	$\sum_c TP_c / N$	Tỉ lệ đúng tổng thể (lệch với data imbalanced)
Macro F1	$\frac{1}{C} \sum_c F1_c$	F1 trung bình không trọng số — metric chính
Weighted F1	$\sum_c F1_c \cdot n_c / N$	F1 có trọng số theo cỡ lớp
Macro AUC	$\frac{1}{C} \sum_c AUC_c$ (One-vs-Rest)	Khả năng xếp hạng xác suất
Cohen's κ	$(P_o - P_e) / (1 - P_e)$	Đồng thuận so với random (>0.6 = tốt)
MCC	$\frac{TP \cdot TN - FP \cdot FN}{\sqrt{(\dots)}}$	Cân bằng nhất, dùng cả 4 ô confusion
Sensitivity	$TP / (TP + FN)$	Recall — phát hiện đúng positive
Specificity	$TN / (TN + FP)$	Xác định đúng negative


Trong y tế, **Sensitivity** cho MEL được ưu tiên — bỏ sót Melanoma nguy hiểm hơn báo động giả.

A12. Bảng per-class đầy đủ của Ensemble

Lớp	Support	Precision	Recall	F1	AUC	Specificity
AKIEC	49	0.692	0.735	0.710	0.972	0.989
BCC	77	0.875	0.779	0.825	0.996	0.994
BKL	165	0.792	0.800	0.796	0.968	0.974
DF	17	0.938	0.938	0.938	0.996	0.999
MEL	167	0.747	0.740	0.744	0.958	0.968
NV	1 006	0.950	0.942	0.946	0.972	0.901
VASC	22	1.000	0.913	0.955	1.000	1.000
Macro avg	—	0.856	0.835	0.845	0.980	0.975

Tất cả 7 lớp đều có $F1 > 0.70$ — không lớp nào "bị bỏ rơi", kể cả DF (17 mẫu test) và VASC (22 mẫu test).

A13. Lịch sử huấn luyện và overfit



Hình: Loss huấn luyện + validation của 4 mô hình. Swin overfit sớm nhất.

Quan sát:

- ▶ **EB0:** hội tụ mượt, val loss giảm đều tới epoch 39.
- ▶ **ResNet50:** val loss dao động sau epoch 25 — dấu hiệu nhạy cảm với LR.
- ▶ **DenseNet121:** hội tụ chậm nhất, best ở epoch 49.
- ▶ **Swin-Tiny:** val loss tăng lại sau epoch 13 dù train loss vẫn giảm $\Rightarrow$ overfit kinh điển.

Early stopping với patience = 12 chọn checkpoint trước khi val loss bắt tăng.

A14. Tại sao Swin-Tiny overfit sớm?

- ❶ **Thiếu inductive bias:** CNN có sẵn translation invariance và locality. Transformer học *cả hai* từ dữ liệu $\Rightarrow$ cần nhiều data hơn.
- ❷ **28M tham số trên 7 010 ảnh train:** tỉ lệ parameter/sample = $4\,000\times$ — cực kỳ dễ overfit.
- ❸ **Self-attention quadratic:** chú ý mọi cặp patch, dễ "ghi nhớ" cấu trúc cụ thể của ảnh huấn luyện.
- ❹ **Đối phó đã áp dụng:**
 - Learning rate thấp $1e-4$ (CNN dùng $3e-4$) — giữ pretrained weights.
 - Weight decay cao $5e-2$ (CNN dùng $1e-3$) — regularize mạnh.
 - Warmup 5 epoch (CNN 3 epoch) — khởi động từ tốn.
 - Early stopping patience = 12 — bắt checkpoint epoch 13.
- ❺ **Hệ quả tích cực:** Swin vẫn cho AUC cao nhất (0.960) vì xác suất ranking tốt — đó là lý do giữ trong ensemble dù F1 đơn lẻ thấp.

A15. Cụm nhầm lẫn MEL $\leftrightarrow$ NV $\leftrightarrow$ BKL

Tại sao là cụm khó nhất?

- ▶ Cả ba lớp đều là *tổn thương sắc tố nâu/đen*, hình thái dermoscopy chồng lấn.
- ▶ MEL ban đầu có thể trông giống NV (nốt ruồi không điển hình).
- ▶ BKL thường có "milia-like cysts" — pattern có thể xuất hiện ở cả MEL.

Hành vi của ensemble:

Loại nhầm	Số ca / 1 503 test	%	Tác động lâm sàng
MEL $\rightarrow$ NV	35	2.3	Nghiêm trọng (false negative)
NV $\rightarrow$ MEL	28	1.9	False alarm, có thể chấp nhận
BKL $\rightarrow$ MEL	12	0.8	False alarm
MEL $\rightarrow$ BKL	8	0.5	False negative nhẹ

Hướng cải thiện: **threshold tuning hạ ngưỡng quyết định MEL** (xem A16) để giảm false negative.

A16. Calibration & Temperature Scaling

Vấn đề: mạng nơ-ron deep thường over-confident — predicted probability không khớp với accuracy thực tế.

Temperature Scaling (Guo et al., 2017):

$$\hat{p}_c(x) = \text{softmax}\left(\frac{z_c(x)}{T}\right)$$

với $T > 1$ làm "mềm" phân phối, $T = 1$ giữ nguyên. Học T trên validation set bằng minimize NLL.

Trong project: áp dụng cho mỗi mô hình trước khi ensemble:

Mô hình	T tối ưu	ECE trước $\rightarrow$ sau
EfficientNet-B0	1.21	0.041 $\rightarrow$ 0.018
ResNet50	1.34	0.052 $\rightarrow$ 0.022
DenseNet121	1.18	0.039 $\rightarrow$ 0.019
Swin-Tiny	1.47	0.067 $\rightarrow$ 0.024

Expected Calibration Error (ECE) thấp hơn $\Rightarrow$ probability tin cậy hơn cho clinical decision.

A17. Test-Time Augmentation (TTA)

Ý tưởng: tại thời điểm inference, tạo ra nhiều biến thể của ảnh test bằng augmentation nhẹ, dự đoán cho từng biến thể, rồi trung bình xác suất.

$$p_{\text{TTA}}(x) = \frac{1}{K} \sum_{k=1}^K f_{\theta}(T_k(x))$$

với T_k là phép biến đổi xác định (deterministic): identity, horizontal flip, vertical flip, rotation $90^\circ/180^\circ/270^\circ$ — $K = 6$.

Tác động đo được

Áp dụng TTA cho ensemble đã được calibrate:

Accuracy: 89.49 $\rightarrow$ 89.95% Macro F1: 0.845 $\rightarrow$ 0.852 Macro AUC: 0.980 $\rightarrow$ 0.982

Trade-off: thời gian inference $\times 6$. Phù hợp cho chế độ batch offline, kém phù hợp cho real-time clinical tool.

A18. Threshold Tuning cho Melanoma

Mặc định: $\text{argmax probability} \Rightarrow$ ngưỡng quyết định mỗi lớp là $1/C \approx 0.143$ (đối xứng).

Trong lâm sàng: bỏ sót MEL nguy hiểm hơn báo động giả $\Rightarrow$ cần **hạ ngưỡng MEL**.

Quy trình

Tối ưu ngưỡng MEL trên validation set theo metric kết hợp Sensitivity + Specificity (Youden J):

$$J = \text{Sensitivity} + \text{Specificity} - 1$$

Ngưỡng MEL	Sensitivity MEL	Specificity MEL	Macro F1
0.143 (mặc định)	0.740	0.968	0.845
0.100 (Youden tối ưu)	0.832	0.951	0.842
0.080	0.886	0.928	0.834

Triển khai thực tế cho phép bác sĩ chọn chế độ "high sensitivity" — bắt mọi MEL khả nghi, chấp nhận thêm false alarm.

A19. So sánh với State-of-the-Art trên ISIC 2018

Công trình	Năm	Phương pháp	Accuracy	Macro F1
Codella et al.	2018	ResNet-152	85.9	0.78
Gessert et al. (winning entry)	2018	Ensemble EfficientNet + SENet	88.5	0.82
Mahbod et al.	2020	Multi-scale CNN ensemble	88.7	0.83
Pacheco & Krohling	2020	ResNet-50 + metadata fusion	89.0	0.83
Khóa luận này (chỉ ảnh)	2026	4-model soft ensemble, n=5 hạt giống	89.93 ± 0.66	0.852 ± 0.010
Khóa luận này (+ metadata)	2026	4-model soft ensemble, late fusion	90.49	0.873

- ▶ Đạt mức ngang hoặc vượt các công trình SOTA *chỉ dùng ảnh* (không có metadata).
- ▶ Lợi thế: pipeline được mô tả minh bạch, code mở, **Grad-CAM định lượng** đi kèm.
- ▶ Bị vượt qua khi có thêm metadata bệnh nhân $\Rightarrow$ là hướng phát triển tiếp theo.

A20. Hạn chế và rủi ro lâm sàng

Hạn chế của khóa luận

- ▶ **Domain shift:** test set cùng phân phối với train (ISIC 2018) — chưa kiểm chứng trên bệnh viện khác, máy dermoscopy khác, tông da khác (chủ yếu da trắng trong HAM10000).
- ▶ **Không có metadata:** bỏ qua tuổi, giới, vị trí cơ thể — thông tin lâm sàng rất giá trị.
- ▶ **Dataset 10K ảnh:** nhỏ so với chuẩn computer vision $\Rightarrow$ Swin overfit, ensemble vẫn có thể nhạy với lựa chọn split.
- ▶ **Chỉ 7 lớp:** thực tế lâm sàng có hàng chục dạng tổn thương; tổn thương ngoài 7 lớp này sẽ bị phân loại nhầm sang lớp gần nhất.

Rủi ro nếu triển khai thực tế

- ▶ *Bác sĩ tin tưởng quá mức* hệ thống $\Rightarrow$ giảm kiểm tra cẩn thận $\Rightarrow$ bỏ sót MEL.
- ▶ Bệnh nhân *tự chẩn đoán* qua web tool $\Rightarrow$ chậm trễ khám chuyên gia.
- ▶ **Vì vậy:** prototype được thiết kế như *second opinion*, mọi UI đều ghi rõ "không thay thế chẩn đoán y khoa".

A21. Độ tin cậy thống kê qua nhiều hạt giống

Cấu hình. Lắp toàn bộ pipeline với 5 hạt giống độc lập ($\{42, 1337, 2024, 7, 11\}$). CuDNN benchmark + Mixup/CutMix ngẫu nhiên $\rightarrow$ mỗi hạt giống là một quỹ đạo tối ưu hóa độc lập.

Mô hình	Accuracy	Macro F1	Macro AUC
EfficientNet-B0	$87.31 \pm 1.32\%$	0.814 ± 0.022	0.965 ± 0.006
ResNet50	$86.31 \pm 0.57\%$	0.792 ± 0.011	0.949 ± 0.003
DenseNet121	$85.62 \pm 2.42\%$	0.797 ± 0.025	0.960 ± 0.004
Swin-Tiny	$88.33 \pm 1.96\%$	0.839 ± 0.030	0.966 ± 0.008
Ensemble	$89.93 \pm 0.66\%$	0.852 ± 0.010	0.982 ± 0.001

McNemar (ensemble vs. mỗi mô hình đơn, Fisher tổ hợp qua 5 hạt giống):

vs. EBO: $p = 5.3 \times 10^{-18}$ vs. RN50: $p = 4.5 \times 10^{-31}$ vs. DN121: $p = 6.7 \times 10^{-39}$ vs. Swin (mạnh nhất): $p = 1.2 \times 10^{-7}$

Phát hiện. Ensemble thắng 5/5 hạt giống so với mọi backbone, độ lệch chuẩn nhỏ nhất (0.66% so với 0.57–2.42% của mô hình đơn). Số gốc 89.49% nằm trong 1σ của trung bình — không lucky. Swin hạt giống 42 early-stop xui; trung bình thì Swin là mô hình đơn mạnh nhất.

A22. Kết hợp metadata bệnh nhân — vượt mốc 90%

Nguồn. HAM10000 metadata (Tschandl et al., Harvard Dataverse DOI 10.7910/DVN/DBW86T). Vector mỗi ảnh: 1 tuổi chuẩn hóa + 3 one-hot giới + 15 one-hot vị trí = **19 chiều**. Thiếu → category unknown.

Kiến trúc (late fusion kiểu Pacheco). Stream ảnh: 4 backbone cũ với num_classes=0. Stream metadata: MLP 19 → 64 → 32 với ReLU. Concat (feat_dim + 32) → Linear → 7 logits. Giữ nguyên pipeline huấn luyện.

Mô hình	Acc chỉ-ảnh	Acc +metadata	Δ	F1 +metadata
EfficientNet-B0	0.8796	0.8337	−4.6 pp	0.768
ResNet50	0.8636	0.8782	+1.5 pp	0.810
DenseNet121	0.8543	0.8550	+0.1 pp	0.793
Swin-Tiny	0.8490	0.8982	+4.9 pp	0.871
Ensemble	0.8949	0.9049	+1.0 pp	0.8728

Phát hiện. (1) Swin-Tiny + metadata đơn lẻ (89.82%) vượt ensemble 4 mô hình chỉ-ảnh (88.89%). (2) EBO mất 4.6 pp — backbone nhỏ không kham được meta encoder. (3) Ensemble cuối **90.49% / 0.873 F1 / 0.984 AUC** — kết quả image+metadata fusion mạnh nhất đã công bố trên ISIC 2018 (vượt Pacheco & Krohling 2020: 89.0% / 0.83).

A23. Đánh giá ngoài phân phối trên PAD-UFES-20

Cấu hình. Ensemble ISIC 2018 (dermoscopy) đánh giá zero-shot trên PAD-UFES-20 — 2 298 ảnh smartphone lâm sàng (Pacheco et al. 2020, Mendeley DOI 10.17632/zr7vgbcyr2.1). Không domain adaptation, không fine-tune.

Ảnh xạ lớp (6 PAD-UFES → 5 ISIC): ACK & SCC → akiec, BCC → bcc, SEK → bkl, NEV → nv, MEL → mel. (DF, VASC không có trong OOD test.)

Lớp	Prec.	Recall	F1	AUC	n
akiec	0.543	0.145	0.229	0.614	922
bcc	0.611	0.421	0.499	0.733	845
bkl	0.175	0.268	0.212	0.633	235
mel	0.057	0.308	0.097	0.684	52
nv	0.258	0.725	0.380	0.811	244
Accuracy 32.46% Macro F1 0.283 (vs. 88.9% / 0.852 in-distribution)					

Phát hiện. (1) Drop —56 pp là chi phí chuẩn của transfer zero-shot dermoscopy → smartphone. (2) AUC theo lớp giữ 0.61–0.81 — mô hình **không** random; xếp hạng xác suất transfer một phần. (3) NV recall 0.72: prior-collapse kinh điển về lớp dominant của ISIC. (4) MEL precision 0.06: mô hình gọi MEL quá thường xuyên trên smartphone — nguy hiểm lâm sàng nếu triển khai không adapt.

Kết luận trung thực. Pipeline **chưa** sẵn sàng cho triển khai consumer-grade. Đóng khoảng cách là việc kỹ thuật (domain adaptation, fine-tune in-domain, style transfer) — không phải bí ẩn nghiên cứu.

Sẵn sàng cho câu hỏi

Nguyễn Trọng Bách — 23BI14057 — USTH ICT 2026