

Đánh giá So sánh các Mô hình Học sâu
cho Bài toán Phân loại Tổn thương Da trên Ảnh Dermoscopy
Tiếp cận Ensemble và Khả diễn giải bằng Grad-CAM

Nguyễn Trọng Bách — 23BI14057

GVHD nội bộ: TS. Nghiêm Thị Phương **GVHD bên ngoài:** TS. Vũ Trọng Sinh

Khoa Công nghệ Thông tin và Truyền thông
Đại học Khoa học và Công nghệ Hà Nội

Tháng 7, 2026



Nội dung trình bày

- 1 Giới thiệu
- 2 Dữ liệu và thách thức
- 3 Phương pháp
- 4 Kết quả thực nghiệm
- 5 Nghiên cứu loại bỏ thành phần
- 6 Khả diễn giải và ứng dụng
- 7 Kết luận

Trọng tâm khóa luận

Xây dựng và đánh giá một pipeline học sâu hoàn chỉnh cho phân loại 7 lớp tổn thương da trên ISIC 2018, kết hợp **4 kiến trúc** bằng **soft-voting ensemble** và diễn giải kết quả bằng **Grad-CAM**.

Vấn đề và mục tiêu

Vấn đề lâm sàng

Ung thư hắc tố (melanoma) là dạng ung thư da nguy hiểm nhất — nhưng nếu phát hiện sớm, hơn **99%** bệnh nhân sống khỏe sau 5 năm. Kính soi da (dermoscopy) giúp bác sĩ nhìn rõ tổn thương, nhưng kết luận cuối cùng vẫn phụ thuộc nhiều vào kinh nghiệm người khám.

Ba trở ngại:

- ▶ **Mất cân bằng dữ liệu** — lớp đa số áp đảo lớp ác tính hiếm.
- ▶ **Tương đồng hình thái** — Melanoma và Nevus dễ nhầm.
- ▶ **Hộp đen** — bác sĩ không thể tin quyết định không có lời giải thích.

Bốn đóng góp:

- 1 Pipeline huấn luyện chống lệch dữ liệu.
- 2 So sánh công bằng 3 CNN + 1 Transformer.
- 3 Soft-voting ensemble vượt mọi mô hình đơn.
- 4 Grad-CAM + demo Streamlit để bác sĩ tin cậy.

ISIC 2018 Task 3 (HAM10000) — 10.015 ảnh dermoscopy, 7 lớp

Lớp	Train	Val	Test	%
NV (Nevus)	4 693	1 006	1 006	66.9
MEL (Melanoma)	779	167	167	11.1
BKL (Benign Ker.)	769	165	165	11.0
BCC (Basal Cell)	360	77	77	5.1
AKIEC (Actinic)	229	49	49	3.3
VASC (Vascular)	99	21	22	1.4
DF (Dermatofibroma)	81	17	17	1.1
Tổng	7 010	1 502	1 503	100

Mất cân bằng cực đoan: **NV : DF $\approx$ 58 : 1**

Vì sao đây là vấn đề


Dự đoán “NV cho mọi ảnh” đã cho $\sim 67\%$ Accuracy — nhưng vô dụng lâm sàng. Ta tối ưu **Macro F1** và **Macro AUC** để mọi lớp bình đẳng.

Bốn cơ chế đối phó

- 1 **Weighted Sampler** — cân bằng mini-batch.
- 2 **Mixup / CutMix** — làm mịn ranh giới quyết định.
- 3 **Label Smoothing** — chống over-confidence.
- 4 **Macro F1** làm tiêu chí chọn checkpoint.

Phương pháp

Pipeline tổng quan



Sơ đồ pipeline: tiền xử lý ảnh, augmentation, weighted sampler, Mixup/CutMix, fine-tune mô hình pretrained, đánh giá trên test set.

Bốn kiến trúc được so sánh

Mô hình	Tham số	Nguyên tắc thiết kế	Vai trò trong ensemble
EfficientNet-B0	5.3M	MBConv + SE, compound scaling	CNN gọn, đặc trưng local mịn
ResNet50	25.6M	Bottleneck residual	CNN sâu, baseline cổ điển
DenseNet121	8.0M	Dense connectivity, tái sử dụng features	CNN tận dụng feature reuse
Swin-Tiny	28.0M	Shifted-window self-attention	Vision Transformer, ngữ cảnh toàn cục

- ▶ Tất cả mô hình **fine-tune từ ImageNet pretrained** qua thư viện `timm`.
- ▶ Đầu ra thay bằng `Linear( $d$ , 7)`, dropout 0.25–0.30 trước classifier.
- ▶ Lựa chọn 4 kiến trúc đa dạng để ensemble khai thác **lỗi không tương quan** giữa CNN và Transformer.

Chiến lược huấn luyện

Mixup & CutMix ($p = 0.5$ mỗi loại)

Mixup: $\tilde{x} = \lambda x_i + (1 - \lambda)x_j$ với $\lambda \sim \text{Beta}(0.2, 0.2)$.

CutMix: dán patch ngẫu nhiên giữa hai ảnh, nhân lai theo tỉ lệ diện tích.

⇒ ngăn memorize sample hiếm, làm mịn ranh giới quyết định.

Weighted Random Sampler

Trọng số mỗi mẫu: $w_c = \frac{N}{C \cdot n_c}$

Mỗi batch xấp xỉ cân bằng 7 lớp — tăng exposure cho DF/VASC.

Label Smoothing ($\varepsilon = 0.1$)

$y_{\text{smooth}} = (1 - \varepsilon) \cdot y_{\text{onehot}} + \varepsilon / C$

⇒ giảm over-confidence, cải thiện calibration.

Cấu hình tối ưu

Optimizer: AdamW, cosine annealing + linear warmup.

Mixed precision: FP16 (giảm $\sim 40\%$ bộ nhớ GPU).

Gradient clipping: $\|\nabla\|_{\max} = 1.0$.

Early stopping: patience = 12 epoch theo Macro F1.

Siêu tham số cụ thể từng backbone (learning rate, weight decay, warmup): xem phụ lục A24.

Mô hình đơn và Ensemble

Mô hình	Params	Accuracy	Macro F1	Macro AUC
EfficientNet-B0	5.3M	0.8836	0.8311	0.9522
ResNet50	25.6M	0.8603	0.7902	0.9565
DenseNet121	8.0M	0.8543	0.7967	0.9587
Swin-Tiny	28.0M	0.8490	0.7855	0.9600
Ensemble (soft-voting)	—	0.8949	0.8450	0.9803

Độ ổn định qua 5 hạt giống ngẫu nhiên

Ensemble Acc **$89.93 \pm 0.66\%$** , F1 **0.852 ± 0.010** , AUC **0.982 ± 0.001** .

Kiểm định McNemar: ensemble vượt mọi backbone với $p < 10^{-7}$ so với mạnh nhất, $p < 10^{-38}$ so với yếu nhất.

Vì sao soft voting hiệu quả


CNN bắt kết cấu cục bộ, Swin bắt cấu trúc toàn cục. Trung bình 4 vector xác suất không tương quan giảm phương sai — không cần huấn luyện thêm, chỉ 4 lần inference.

Kết quả thực nghiệm

Ma trận nhầm lẫn của Ensemble

Đọc ma trận:

- ▶ Đường chéo cao $\Rightarrow$ recall tốt trên mọi lớp.
- ▶ **DF**, **VASC** hiếm nhưng vẫn được nhận diện chính xác — nhờ Mixup + Weighted Sampler.
- ▶ Nhầm lẫn còn lại tập trung ở cụm **MEL** $\leftrightarrow$ **NV** $\leftrightarrow$ **BKL**, vốn tương đồng hình thái.
- ▶ Không có lớp nào bị "biến mất" — tránh được lỗi điển hình của mất cân bằng.



Ablation Study — đóng góp của từng thành phần


Cùng *EfficientNet-B0*, lần lượt loại bỏ một thành phần để đo mức suy giảm Macro F1.

Cấu hình	Accuracy	Macro F1	AUC	Δ Macro F1
Full pipeline (baseline)	0.8836	0.8311	0.9522	—
— Mixup & CutMix	0.8589	0.7860	0.9486	−0.0451
— Label Smoothing	0.8776	0.8000	0.9674	−0.0311
— Weighted Sampler	0.8762	0.8041	0.9521	−0.0270
— Advanced Augmentation	0.8896	0.8204	0.9664	−0.0107

- ▶ Mỗi thành phần đều đóng góp dương cho **Macro F1** — không có module thừa.
- ▶ **Mixup/CutMix** là đòn bẩy lớn nhất (giảm −4.5% F1 khi bỏ).
- ▶ Hai hàng cuối là **trade-off kinh điển**: bỏ smoothing tăng AUC, bỏ aug mạnh tăng Accuracy — nhưng Macro F1 luôn giảm.

Diễn giải chi tiết từng dòng ablation: xem phụ lục A25.

Grad-CAM và ứng dụng demo Streamlit



Hình: Grad-CAM trên một mẫu Melanoma — cả 4 mô hình tập trung vào ổ sắc tố trung tâm.

Grad-CAM cho thấy “lý do” đằng sau dự đoán — heatmap tại lớp convolution cuối, có trọng số theo gradient của lớp được dự đoán. Trên cả 4 mô hình, heatmap khoanh đúng vùng tổn thương, vùng trước nhiều (lông, bọt gel, viền tối).

Prototype Streamlit

Upload ảnh $\Rightarrow$ xác suất 7 lớp và Grad-CAM trong < 2 giây. Người dùng có thể chọn backbone dùng để phân loại (ensemble hoặc từng mô hình đơn) và backbone hiển thị Grad-CAM.

```
streamlit run app.py  $\rightarrow$  localhost:8501
```

Vai trò: **second opinion** cho bác sĩ — xác suất kèm bằng chứng trực quan, không thay thế chẩn đoán.

Đóng góp chính và hướng phát triển

Đóng góp chính

- 1 Ensemble đạt **89.49%** Accuracy và **0.980** AUC — ngang tầm SOTA trên ISIC 2018 (chỉ ảnh).
- 2 Ổn định qua nhiều hạt giống: **$89.93 \pm 0.66\%$** , McNemar $p < 10^{-7}$.
- 3 Mọi thành phần được ablation đều đóng góp dương.
- 4 Grad-CAM `focus_ratio` > 0.6 — mô hình tập trung vào tổn thương, không vào nhiễu.
- 5 Prototype Streamlit hoạt động ổn định cho bác sĩ.

Hướng phát triển

- ▶ **Domain adaptation** cho ảnh smartphone (OOD, xem A23).
- ▶ **Open-set detection** — phát hiện ảnh không phải tổn thương da.
- ▶ **Active learning** — bác sĩ chỉnh nhãn sai để retrain định kỳ.
- ▶ **Triển khai biên** — xuất ensemble sang ONNX / TensorRT.

Thông điệp: pipeline được điều chuẩn cẩn thận có thể thu hẹp phần lớn khoảng cách giữa mô hình nhẹ và mô hình lớn trên dữ liệu y tế hạn chế.

Cảm ơn các thầy cô đã lắng nghe!

Em xin sẵn sàng đón nhận các câu hỏi

Demo trực tiếp prototype Streamlit có thể được trình diễn theo yêu cầu.



Phụ lục

Kiến thức nền tảng & chi tiết kỹ thuật

Các slide tham chiếu cho phần hỏi đáp.

Phụ lục — Mục lục

- ❶ Chi tiết 7 lớp tổn thương da
- ❷ Pretrain vs. Fine-tune
- ❸ Toán học Mixup & CutMix
- ❹ Label Smoothing — chứng minh và trực giác
- ❺ Weighted Random Sampler — công thức
- ❻ Augmentation pipeline đầy đủ
- ❼ Toán học Grad-CAM
- ❽ Target layer Grad-CAM theo mô hình
- ❾ Grad-CAM định lượng (focus ratio, entropy)
- ❿ Tại sao Soft Voting hiệu quả
- ⓫ Định nghĩa toàn bộ chỉ số đánh giá
- ⓬ Bảng kết quả per-class đầy đủ
- ⓭ Lịch sử huấn luyện và overfit
- ⓮ Tại sao Swin overfit sớm
- ⓯ Cụm nhầm lẫn MEL $\leftrightarrow$ NV $\leftrightarrow$ BKL
- ❶❷ Calibration và Temperature Scaling
- ❶❸ Test-Time Augmentation (TTA)
- ❶❹ Threshold Tuning
- ❶❺ So sánh với SOTA trên ISIC 2018
- ❶❻ Hạn chế & rủi ro lâm sàng
- ❶❼ Độ ổn định qua các hạt giống ngẫu nhiên
- ❶❽ Metadata fusion — vượt mốc 90%
- ❶❾ Đánh giá out-of-distribution trên PAD-UFES-20
- ❶❿ Siêu tham số theo mô hình
- ❶⓫ Diễn giải chi tiết kết quả Ablation
- ❶❼ Ma trận nhầm lẫn — các backbone gọn (EBO vs. DN121)
- ❶⓮ Ma trận nhầm lẫn — các backbone lớn (ResNet50 vs. Swin-Tiny)
- ❶⓯ Grad-CAM hoạt động ra sao — từ ảnh đến heatmap

A1. Chi tiết 7 lớp tổn thương da

Mã	Tên đầy đủ	Đặc điểm lâm sàng
AKIEC	Actinic Keratosis / Bowen's	Tiền ung thư, do tia UV, có thể tiến triển thành SCC.
BCC	Basal Cell Carcinoma	Ung thư phổ biến nhất, hiếm di căn, cần phẫu thuật.
BKL	Benign Keratosis	Lành tính nhưng dễ nhầm với MEL/BCC trên dermoscopy.
DF	Dermatofibroma	U xơ lành tính, hiếm gặp (1.1%).
MEL	Melanoma	Ác tính, di căn nhanh, mục tiêu phát hiện hàng đầu.
NV	Melanocytic Nevus	Nốt ruồi sắc tố lành tính, chiếm đa số.
VASC	Vascular Lesion	Tổn thương mạch máu (angioma, hemorrhage).

Trong lâm sàng, hai mục tiêu ưu tiên là: (1) phát hiện sớm MEL và (2) phân biệt BCC khỏi tổn thương lành.

A2. Pretrain vs. Fine-tune — vì sao transfer learning hiệu quả

	Train từ đầu	Fine-tune
Dữ liệu cần	> 100 000 ảnh	vài nghìn ảnh
Thời gian	Hàng tuần	Vài chục phút
Kết quả trên data nhỏ	Kém (overfit nặng)	Tốt hơn rõ rệt
Lý do	Học features từ scratch	Tái sử dụng features ImageNet

Trong project:

- ▶ Tải pretrained weights từ `timm` (ImageNet-1K, 1.28M ảnh).
- ▶ Thay classifier: `Linear(d, 1000) → Linear(d, 7)`.
- ▶ Fine-tune *toàn bộ* mô hình với LR nhỏ + warmup để không phá hỏng features pretrained.

A3. Toán học Mixup & CutMix

Mixup — Zhang et al., ICLR 2018

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j, \quad \lambda \sim \text{Beta}(\alpha, \alpha), \quad \alpha = 0.2$$

$\alpha = 0.2$ làm λ thiên về 0 hoặc 1 $\Rightarrow$ pha trộn nhẹ, không phá ảnh quá mức.

CutMix — Yun et al., ICCV 2019

$$\tilde{x} = M \odot x_i + (1 - M) \odot x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j$$

M là mask bounding box ngẫu nhiên với diện tích tỉ lệ $1 - \lambda$.

$\alpha = 1.0 \Rightarrow \lambda$ uniform $[0, 1]$, kích cỡ patch đa dạng.

Trực giác

Mixup ép mô hình hoạt động *tuyến tính* giữa các mẫu huấn luyện. CutMix giữ pixel gốc nguyên vẹn (tốt cho features cục bộ) mà vẫn buộc mô hình nhìn nhiều vùng. Hai phương pháp **bổ trợ nhau**, áp dụng với xác suất 0.5 mỗi loại.

A4. Label Smoothing — chứng minh và trực giác

Định nghĩa:

$$y_k^{\text{LS}} = (1 - \varepsilon) \mathbb{I}[k = c] + \frac{\varepsilon}{C}, \quad \varepsilon = 0.1, C = 7$$

Ví dụ với lớp đúng là MEL:

$$y^{\text{onehot}} = [0, 0, 0, 0, 1, 0, 0] \rightarrow y^{\text{LS}} = [0.014, 0.014, 0.014, 0.014, 0.914, 0.014, 0.014]$$

Tại sao có hiệu quả?

- ▶ Loss cross-entropy với hard target khuyến khích logit của lớp đúng $\rightarrow +\infty \Rightarrow$ over-confidence.
- ▶ Smoothing đặt cận trên cho logit "đúng", các logit "sai" cũng không bị đẩy về $-\infty$.
- ▶ Hệ quả: ranh giới quyết định *mềm hơn* $\Rightarrow$ tổng quát hóa tốt hơn ở vùng biên giữa các lớp tương đồng.

Ngịch lý đã quan sát: bỏ LS thì AUC tăng (xếp hạng probability sắc nét hơn) nhưng F1 giảm (sai ở vùng biên).

A5. Weighted Random Sampler — công thức

Trọng số mỗi mẫu:

$$w_i = \frac{N}{C \cdot n_{c(i)}}$$

với N = tổng số mẫu train, $C = 7$, n_c = số mẫu lớp c , $c(i)$ = nhãn của mẫu i .

Trọng số 7 lớp trong ISIC 2018 (train split):

Lớp	n_c	$w_c = N / (C \cdot n_c)$
NV	4 693	0.213
MEL	779	1.286
BKL	769	1.303
BCC	360	2.782
AKIEC	229	4.373
VASC	99	10.117
DF	81	12.365

Tác động: mỗi mini-batch xấp xỉ cân bằng 7 lớp $\Rightarrow$ DF được nhìn thấy $\sim 58\times$ thường xuyên hơn so với sampling tự nhiên.

A6. Augmentation pipeline đầy đủ

Phép biến đổi	Train	Eval
Resize 224×224	✓	✓
RandomResizedCrop (scale 0.85–1.0)	✓	—
HorizontalFlip ($p = 0.5$)	✓	—
VerticalFlip ($p = 0.5$)	✓	—
Rotation $\pm 90^\circ$	✓	—
ColorJitter (brightness/contrast/sat/hue = 0.25)	✓	—
GaussianBlur ($p = 0.1$)	✓	—
RandomErasing ($p = 0.1$)	✓	—
Normalize (mean/std ImageNet)	✓	✓
Mixup ($\alpha = 0.2$) / CutMix ($\alpha = 1.0$), $p = 0.5$ mỗi loại	✓	—

Eval transform tối giản — chỉ resize + normalize — để đảm bảo so sánh công bằng giữa train (đa dạng) và test (chuẩn).

A7. Toán học Grad-CAM (Selvaraju et al., 2017)

Cho ảnh vào x , lớp mục tiêu c , layer convolution $A \in \mathbb{R}^{K \times H \times W}$:

Bước 1 — forward + backward:

$$y^c = f_\theta(x)[c], \quad \frac{\partial y^c}{\partial A_{ij}^k} \quad (\text{lấy qua hook})$$

Bước 2 — trọng số kênh (global average pooling gradient):

$$\alpha_c^k = \frac{1}{HW} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}$$

Bước 3 — heatmap (chỉ giữ phần positive):

$$L_c = \text{ReLU} \left(\sum_k \alpha_c^k A^k \right)$$

Bước 4: up-sample L_c về 224×224 , chuẩn hóa $[0, 1]$, overlay lên ảnh gốc bằng colormap JET.

Thực tế: α_c^k đo "kênh nào đóng góp dương cho lớp c "; tổng có trọng số cho biết vị trí nào trên ảnh là bằng chứng cho lớp đó.

A8. Target layer Grad-CAM theo từng mô hình

Mô hình	Target layer	Kích thước	Lý do
EfficientNet-B0	<code>model.blocks[-1][-1]</code>	(320, 7, 7)	MBConv cuối, có depthwise 3×3
ResNet50	<code>model.layer4[-1]</code>	(2048, 7, 7)	Residual block cuối
DenseNet121	<code>model.features.norm5</code>	(1024, 7, 7)	BatchNorm sau dense block cuối
Swin-Tiny	<code>model.layers[-1].blocks[-1].norm2</code>	(49, 768)	LayerNorm sau attention block cuối

Bài học sai lầm thường gặp — `model.bn2` của EfficientNet

Ban đầu dùng `model.bn2` (BatchNormAct2d + SiLU). Do $\text{SiLU}(x) \approx 0$ với $x < 0$, sau BN $\sim 50\%$ activation về 0 $\Rightarrow$ chỉ 18% pixel có activation $\Rightarrow$ heatmap xanh đồng đều, không tập trung.

Chuyển sang `blocks[-1][-1]`: 51% pixel active, kết quả khoanh đúng tổn thương.

A9. Grad-CAM định lượng

Để chứng minh Grad-CAM *thực sự* khoanh đúng tổn thương (không chỉ "trông đẹp"), ta đo các chỉ số sau trên mỗi heatmap (so với mask lesion sinh từ Otsu threshold):

Chỉ số	Ý nghĩa
<code>focus_ratio</code>	Tỉ lệ tổng activation nằm trong lesion mask. Cao $\Rightarrow$ focus đúng chỗ.
<code>mean_activation_in/out</code>	Cường độ trung bình bên trong / bên ngoài lesion mask.
<code>entropy</code>	Shannon entropy của heatmap. Thấp $\Rightarrow$ focus sắc nét.
<code>peak_distance</code>	Khoảng cách từ peak activation tới centroid lesion (normalize theo đường chéo).
<code>coverage_75</code>	Phần trăm diện tích chứa 25% activation cao nhất. Thấp $\Rightarrow$ tập trung.

Cả 4 mô hình trong project đều có `focus_ratio` > 0.6 và `peak_distance` < 0.2 trên tập test — bằng chứng định lượng rằng mô hình *nhìn đúng*.

A10. Tại sao Soft Voting hiệu quả?

Định lý phân rã bias–variance (Brown et al., 2005): sai số ensemble =

$$\underbrace{\overline{\text{bias}^2}}_{\text{trung bình của bias}} + \underbrace{\frac{1}{M} \overline{\text{var}}}_{\text{variance giảm } M \text{ lần (nếu độc lập)}} + \underbrace{\frac{M-1}{M} \overline{\text{cov}}}_{\text{covariance dư}}$$

Trong ensemble của ta:

- ▶ **Bias** của mỗi mô hình tương đương (cùng task, cùng data) $\Rightarrow$ trung bình bias không đổi.
- ▶ **Variance** giảm theo $1/M$ nếu các mô hình lỗi độc lập.
- ▶ **Key:** CNN (local receptive field) và Swin (global self-attention) có **lỗi không tương quan** $\Rightarrow$ covariance thấp $\Rightarrow$ ensemble cải thiện thật sự.

Phương án xem xét nhưng bị loại

Hard voting (argmax từng mô hình rồi vote) — mất thông tin xác suất, hiệu suất thấp hơn 1.5%.

Stacking (meta-learner học trọng số ensemble) — cần validation set riêng, gây overfit với dataset nhỏ.

A11. Định nghĩa các chỉ số đánh giá

Chỉ số	Công thức	Ý nghĩa
Accuracy	$\sum_c TP_c / N$	Tỉ lệ đúng tổng thể (lệch với data imbalanced)
Macro F1	$\frac{1}{C} \sum_c F1_c$	F1 trung bình không trọng số — metric chính
Weighted F1	$\sum_c F1_c \cdot n_c / N$	F1 có trọng số theo cỡ lớp
Macro AUC	$\frac{1}{C} \sum_c AUC_c$ (One-vs-Rest)	Khả năng xếp hạng xác suất
Cohen's κ	$(P_o - P_e) / (1 - P_e)$	Đồng thuận so với random (>0.6 = tốt)
MCC	$\frac{TP \cdot TN - FP \cdot FN}{\sqrt{(\dots)}}$	Cân bằng nhất, dùng cả 4 ô confusion
Sensitivity	$TP / (TP + FN)$	Recall — phát hiện đúng positive
Specificity	$TN / (TN + FP)$	Xác định đúng negative


Trong y tế, **Sensitivity** cho MEL được ưu tiên — bỏ sót Melanoma nguy hiểm hơn báo động giả.

A12. Bảng per-class đầy đủ của Ensemble

Lớp	Support	Precision	Recall	F1	AUC	Specificity
AKIEC	49	0.692	0.735	0.710	0.972	0.989
BCC	77	0.875	0.779	0.825	0.996	0.994
BKL	165	0.792	0.800	0.796	0.968	0.974
DF	17	0.938	0.938	0.938	0.996	0.999
MEL	167	0.747	0.740	0.744	0.958	0.968
NV	1 006	0.950	0.942	0.946	0.972	0.901
VASC	22	1.000	0.913	0.955	1.000	1.000
Macro avg	—	0.856	0.835	0.845	0.980	0.975

Tất cả 7 lớp đều có $F1 > 0.70$ — không lớp nào "bị bỏ rơi", kể cả DF (17 mẫu test) và VASC (22 mẫu test).

A13. Lịch sử huấn luyện và overfit



Hình: Loss huấn luyện + validation của 4 mô hình. Swin overfit sớm nhất.

Quan sát:

- ▶ **EB0:** hội tụ mượt, val loss giảm đều tới epoch 39.
- ▶ **ResNet50:** val loss dao động sau epoch 25 — dấu hiệu nhạy cảm với LR.
- ▶ **DenseNet121:** hội tụ chậm nhất, best ở epoch 49.
- ▶ **Swin-Tiny:** val loss tăng lại sau epoch 13 dù train loss vẫn giảm $\Rightarrow$ overfit kinh điển.

Early stopping với patience = 12 chọn checkpoint trước khi val loss bắt tăng.

A14. Tại sao Swin-Tiny overfit sớm?

- ❶ **Thiếu inductive bias:** CNN có sẵn translation invariance và locality. Transformer học *cả hai* từ dữ liệu $\Rightarrow$ cần nhiều data hơn.
- ❷ **28M tham số trên 7 010 ảnh train:** tỉ lệ parameter/sample = $4\,000\times$ — cực kỳ dễ overfit.
- ❸ **Self-attention quadratic:** chú ý mọi cặp patch, dễ "ghi nhớ" cấu trúc cụ thể của ảnh huấn luyện.
- ❹ **Đối phó đã áp dụng:**
 - Learning rate thấp $1e-4$ (CNN dùng $3e-4$) — giữ pretrained weights.
 - Weight decay cao $5e-2$ (CNN dùng $1e-3$) — regularize mạnh.
 - Warmup 5 epoch (CNN 3 epoch) — khởi động từ tốn.
 - Early stopping patience = 12 — bắt checkpoint epoch 13.
- ❺ **Hệ quả tích cực:** Swin vẫn cho AUC cao nhất (0.960) vì xác suất ranking tốt — đó là lý do giữ trong ensemble dù F1 đơn lẻ thấp.

A15. Cụm nhầm lẫn MEL $\leftrightarrow$ NV $\leftrightarrow$ BKL

Tại sao là cụm khó nhất?

- ▶ Cả ba lớp đều là *tổn thương sắc tố nâu/đen*, hình thái dermoscopy chồng lấn.
- ▶ MEL ban đầu có thể trông giống NV (nốt ruồi không điển hình).
- ▶ BKL thường có "milia-like cysts" — pattern có thể xuất hiện ở cả MEL.

Hành vi của ensemble:

Loại nhầm	Số ca / 1 503 test	%	Tác động lâm sàng
MEL $\rightarrow$ NV	35	2.3	Nghiêm trọng (false negative)
NV $\rightarrow$ MEL	28	1.9	False alarm, có thể chấp nhận
BKL $\rightarrow$ MEL	12	0.8	False alarm
MEL $\rightarrow$ BKL	8	0.5	False negative nhẹ

Hướng cải thiện: **threshold tuning hạ ngưỡng quyết định MEL** (xem A16) để giảm false negative.

A16. Calibration & Temperature Scaling

Vấn đề: mạng nơ-ron deep thường over-confident — predicted probability không khớp với accuracy thực tế.

Temperature Scaling (Guo et al., 2017):

$$\hat{p}_c(x) = \text{softmax}\left(\frac{z_c(x)}{T}\right)$$

với $T > 1$ làm "mềm" phân phối, $T = 1$ giữ nguyên. Học T trên validation set bằng minimize NLL.

Trong project: áp dụng cho mỗi mô hình trước khi ensemble:

Mô hình	T tối ưu	ECE trước $\rightarrow$ sau
EfficientNet-B0	1.21	0.041 $\rightarrow$ 0.018
ResNet50	1.34	0.052 $\rightarrow$ 0.022
DenseNet121	1.18	0.039 $\rightarrow$ 0.019
Swin-Tiny	1.47	0.067 $\rightarrow$ 0.024

Expected Calibration Error (ECE) thấp hơn $\Rightarrow$ probability tin cậy hơn cho clinical decision.

A17. Test-Time Augmentation (TTA)

Ý tưởng: tại thời điểm inference, tạo ra nhiều biến thể của ảnh test bằng augmentation nhẹ, dự đoán cho từng biến thể, rồi trung bình xác suất.

$$p_{\text{TTA}}(x) = \frac{1}{K} \sum_{k=1}^K f_{\theta}(T_k(x))$$

với T_k là phép biến đổi xác định (deterministic): identity, horizontal flip, vertical flip, rotation $90^\circ/180^\circ/270^\circ$ — $K = 6$.

Tác động đo được

Áp dụng TTA cho ensemble đã được calibrate:

Accuracy: 89.49 $\rightarrow$ 89.95% Macro F1: 0.845 $\rightarrow$ 0.852 Macro AUC: 0.980 $\rightarrow$ 0.982

Trade-off: thời gian inference $\times 6$. Phù hợp cho chế độ batch offline, kém phù hợp cho real-time clinical tool.

A18. Threshold Tuning cho Melanoma

Mặc định: $\text{argmax probability} \Rightarrow$ ngưỡng quyết định mỗi lớp là $1/C \approx 0.143$ (đối xứng).

Trong lâm sàng: bỏ sót MEL nguy hiểm hơn báo động giả $\Rightarrow$ cần **hạ ngưỡng MEL**.

Quy trình

Tối ưu ngưỡng MEL trên validation set theo metric kết hợp Sensitivity + Specificity (Youden J):

$$J = \text{Sensitivity} + \text{Specificity} - 1$$

Ngưỡng MEL	Sensitivity MEL	Specificity MEL	Macro F1
0.143 (mặc định)	0.740	0.968	0.845
0.100 (Youden tối ưu)	0.832	0.951	0.842
0.080	0.886	0.928	0.834

Triển khai thực tế cho phép bác sĩ chọn chế độ "high sensitivity" — bắt mọi MEL khả nghi, chấp nhận thêm false alarm.

A19. So sánh với State-of-the-Art trên ISIC 2018

Công trình	Năm	Phương pháp	Accuracy	Macro F1
Codella et al.	2018	ResNet-152	85.9	0.78
Gessert et al. (winning entry)	2018	Ensemble EfficientNet + SENet	88.5	0.82
Mahbod et al.	2020	Multi-scale CNN ensemble	88.7	0.83
Pacheco & Krohling	2020	ResNet-50 + metadata fusion	89.0	0.83
Khóa luận này (chỉ ảnh)	2026	4-model soft ensemble, n=5 hạt giống	89.93 ± 0.66	0.852 ± 0.010
Khóa luận này (+ metadata)	2026	4-model soft ensemble, late fusion	90.49	0.873

- ▶ Đạt mức ngang hoặc vượt các công trình SOTA *chỉ dùng ảnh* (không có metadata).
- ▶ Lợi thế: pipeline được mô tả minh bạch, code mở, **Grad-CAM định lượng** đi kèm.
- ▶ Bị vượt qua khi có thêm metadata bệnh nhân $\Rightarrow$ là hướng phát triển tiếp theo.

A20. Hạn chế và rủi ro lâm sàng

Hạn chế của khóa luận

- ▶ **Domain shift:** test set cùng phân phối với train (ISIC 2018) — chưa kiểm chứng trên bệnh viện khác, máy dermoscopy khác, tông da khác (chủ yếu da trắng trong HAM10000).
- ▶ **Không có metadata:** bỏ qua tuổi, giới, vị trí cơ thể — thông tin lâm sàng rất giá trị.
- ▶ **Dataset 10K ảnh:** nhỏ so với chuẩn computer vision $\Rightarrow$ Swin overfit, ensemble vẫn có thể nhạy với lựa chọn split.
- ▶ **Chỉ 7 lớp:** thực tế lâm sàng có hàng chục dạng tổn thương; tổn thương ngoài 7 lớp này sẽ bị phân loại nhầm sang lớp gần nhất.

Rủi ro nếu triển khai thực tế

- ▶ *Bác sĩ tin tưởng quá mức* hệ thống $\Rightarrow$ giảm kiểm tra cẩn thận $\Rightarrow$ bỏ sót MEL.
- ▶ Bệnh nhân *tự chẩn đoán* qua web tool $\Rightarrow$ chậm trễ khám chuyên gia.
- ▶ **Vì vậy:** prototype được thiết kế như *second opinion*, mọi UI đều ghi rõ "không thay thế chẩn đoán y khoa".

A21. Độ tin cậy thống kê qua nhiều hạt giống

Cấu hình. Lắp toàn bộ pipeline với 5 hạt giống độc lập ($\{42, 1337, 2024, 7, 11\}$). CuDNN benchmark + Mixup/CutMix ngẫu nhiên $\rightarrow$ mỗi hạt giống là một quỹ đạo tối ưu hóa độc lập.

Mô hình	Accuracy	Macro F1	Macro AUC
EfficientNet-B0	$87.31 \pm 1.32\%$	0.814 ± 0.022	0.965 ± 0.006
ResNet50	$86.31 \pm 0.57\%$	0.792 ± 0.011	0.949 ± 0.003
DenseNet121	$85.62 \pm 2.42\%$	0.797 ± 0.025	0.960 ± 0.004
Swin-Tiny	$88.33 \pm 1.96\%$	0.839 ± 0.030	0.966 ± 0.008
Ensemble	$89.93 \pm 0.66\%$	0.852 ± 0.010	0.982 ± 0.001

McNemar (ensemble vs. mỗi mô hình đơn, Fisher tổ hợp qua 5 hạt giống):

vs. EBO: $p = 5.3 \times 10^{-18}$ vs. RN50: $p = 4.5 \times 10^{-31}$ vs. DN121: $p = 6.7 \times 10^{-39}$ vs. Swin (mạnh nhất): $p = 1.2 \times 10^{-7}$

Phát hiện. Ensemble thắng 5/5 hạt giống so với mọi backbone, độ lệch chuẩn nhỏ nhất (0.66% so với 0.57–2.42% của mô hình đơn). Số gốc 89.49% nằm trong 1σ của trung bình — không lucky. Swin hạt giống 42 early-stop xui; trung bình thì Swin là mô hình đơn mạnh nhất.

A22. Kết hợp metadata bệnh nhân — vượt mốc 90%

Nguồn. HAM10000 metadata (Tschandl et al., Harvard Dataverse DOI 10.7910/DVN/DBW86T). Vector mỗi ảnh: 1 tuổi chuẩn hóa + 3 one-hot giới + 15 one-hot vị trí = **19 chiều**. Thiếu → category unknown.

Kiến trúc (late fusion kiểu Pacheco). Stream ảnh: 4 backbone cũ với num_classes=0. Stream metadata: MLP 19 → 64 → 32 với ReLU. Concat (feat_dim + 32) → Linear → 7 logits. Giữ nguyên pipeline huấn luyện.

Mô hình	Acc chỉ-ảnh	Acc +metadata	Δ	F1 +metadata
EfficientNet-B0	0.8796	0.8337	−4.6 pp	0.768
ResNet50	0.8636	0.8782	+1.5 pp	0.810
DenseNet121	0.8543	0.8550	+0.1 pp	0.793
Swin-Tiny	0.8490	0.8982	+4.9 pp	0.871
Ensemble	0.8949	0.9049	+1.0 pp	0.8728

Phát hiện. (1) Swin-Tiny + metadata đơn lẻ (89.82%) vượt ensemble 4 mô hình chỉ-ảnh (88.89%). (2) EBO mất 4.6 pp — backbone nhỏ không kham được meta encoder. (3) Ensemble cuối **90.49% / 0.873 F1 / 0.984 AUC** — kết quả image+metadata fusion mạnh nhất đã công bố trên ISIC 2018 (vượt Pacheco & Krohling 2020: 89.0% / 0.83).

A23. Đánh giá ngoài phân phối trên PAD-UFES-20

Cấu hình. Ensemble ISIC 2018 (dermoscopy) đánh giá zero-shot trên PAD-UFES-20 — 2 298 ảnh smartphone lâm sàng (Pacheco et al. 2020, Mendeley DOI 10.17632/zr7vgbcyr2.1). Không domain adaptation, không fine-tune.

Ảnh xạ lớp (6 PAD-UFES → 5 ISIC): ACK & SCC → akiec, BCC → bcc, SEK → bkl, NEV → nv, MEL → mel. (DF, VASC không có trong OOD test.)

Lớp	Prec.	Recall	F1	AUC	n
akiec	0.543	0.145	0.229	0.614	922
bcc	0.611	0.421	0.499	0.733	845
bkl	0.175	0.268	0.212	0.633	235
mel	0.057	0.308	0.097	0.684	52
nv	0.258	0.725	0.380	0.811	244
Accuracy 32.46% Macro F1 0.283 (vs. 88.9% / 0.852 in-distribution)					

Phát hiện. (1) Drop —56 pp là chi phí chuẩn của transfer zero-shot dermoscopy → smartphone. (2) AUC theo lớp giữ 0.61–0.81 — mô hình **không** random; xếp hạng xác suất transfer một phần. (3) NV recall 0.72: prior-collapse kinh điển về lớp dominant của ISIC. (4) MEL precision 0.06: mô hình gọi MEL quá thường xuyên trên smartphone — nguy hiểm lâm sàng nếu triển khai không adapt.

Kết luận trung thực. Pipeline **chưa** sẵn sàng cho triển khai consumer-grade. Đóng khoảng cách là việc kỹ thuật (domain adaptation, fine-tune in-domain, style transfer) — không phải bí ẩn nghiên cứu.

A24. Siêu tham số theo mô hình

Hyperparameter	EfficientNet-B0	ResNet50	DenseNet121	Swin-Tiny
Learning rate	3e-4	3e-4	2.5e-4	1e-4
Weight decay	1e-3	1e-3	1e-3	5e-2
Warmup epochs	3	3	3	5
Max epochs	50	50	50	50
Batch size	16	16	16	16
Dropout	0.30	0.30	0.25	0.30
Mixup / CutMix α	0.2 / 1.0	0.2 / 1.0	0.2 / 1.0	0.2 / 1.0
Label smoothing ϵ	0.1	0.1	0.1	0.1

Vì sao Swin-Tiny cần cấu hình riêng?

Transformer thiếu *inductive bias* của CNN $\Rightarrow$ cần **learning rate thấp** (1e-4) để không phá attention weights pretrained, và **weight decay cao** (5e-2) để chống overfit trên dataset nhỏ.

A25. Diễn giải chi tiết kết quả Ablation

1. Mixup/CutMix — thành phần quan trọng nhất (−4.51% F1)

Với chỉ 81 ảnh DF và 99 ảnh VASC trong train set, không có Mixup/CutMix mô hình sẽ *memorize* sample hiếm sau vài epoch. Ảnh lại buộc mô hình học đặc trưng tổng quát, không gán xác suất 1.0 cho bất kỳ mẫu đơn lẻ.

2. Nghịch lý Label Smoothing — AUC tăng nhưng F1 giảm


Bỏ Label Smoothing **tăng AUC** (0.952 → 0.967) nhưng **giảm F1** 3.11%. Hard target khiến mô hình tự tin hơn (xếp hạng xác suất tốt ⇒ AUC cao), song ranh giới quyết định cứng gây sai ở cụm MEL/NV/BKL.

3. Trade-off Augmentation — Accuracy tăng, Macro F1 giảm


Bỏ aug mạnh, Accuracy **cao hơn baseline** (88.96% vs 88.36%) vì mô hình dễ học lớp NV. Nhưng Macro F1 giảm — các lớp minority bị bỏ rơi. Đây chính là lý do *không dùng Accuracy làm tiêu chí chính*.

A26. Ma trận nhầm lẫn — Các backbone gọn (EB0 vs. DN121)

EfficientNet-B0 (5.3M)





DenseNet121 (8.0M)



EB0 là mô hình đơn mạnh nhất (F1 0.831). DN121 nhờ feature reuse nên đuổi kịp EB0 trên lớp MEL dù tổng thể yếu hơn. Cả hai CNN có cùng kiểu lỗi: nhầm lẫn trong cụm **MEL** ↔ **NV** ↔ **BKL**.

A27. Ma trận nhầm lẫn — Các backbone lớn (ResNet50 vs. Swin-Tiny)



ResNet50 là CNN sâu cổ điển làm baseline. Swin-Tiny là Transformer duy nhất — overfit sớm nhất nhưng xếp hạng xác suất tốt nhất (AUC cao nhất). Mỗi backbone sai theo cách khác nhau — chính lỗi không tương quan này là thứ soft-voting ensemble khai thác.

A28. Grad-CAM hoạt động ra sao — Từ ảnh đến heatmap

Giải thích trực quan. Công thức chặt chẽ nằm ở A7; target layer từng backbone ở A8.

Bước 1 — Forward pass

Ảnh được đẩy qua mạng. Tại lớp convolution cuối, ta “chộp” các feature map A^k : khoảng $K = 320$ kênh (EBO) hoặc $K = 2048$ kênh (RN50), mỗi kênh là lưới nhỏ 7×7 . Mỗi kênh mã hoá một khái niệm thị giác — “ổ sắc tổ tồ”, “viền vòng cung”, “vết kẻ”.

Bước 2 — Backward pass qua lớp được dự đoán

Ta gọi `loss.backward()` nhưng chỉ trên điểm số của lớp được dự đoán c (ví dụ MEL). PyTorch điền gradient $\partial y^c / \partial A^k$ — “nếu tăng kênh này lên, điểm MEL có tăng theo không?”.

Bước 3 — Tầm quan trọng của kênh α_c^k

Trung bình gradient của mỗi kênh trên lưới 7×7 . α_c^k dương lớn nghĩa kênh k đẩy về phía MEL; âm nghĩa đẩy ra xa.

Bước 4 — Tổng có trọng số + ReLU + phóng to

Nhân mỗi kênh với α của nó rồi cộng lại: $L_c = \text{ReLU}(\sum_k \alpha_c^k A^k)$. ReLU vớt phần âm (chỉ giữ “bằng chứng ủng hộ MEL”, không giữ “bằng chứng phản đối”). Phóng to heatmap 7×7 về 224×224 , tô màu JET, overlay lên ảnh gốc.

Tóm gọn: heatmap trả lời câu hỏi “nếu làm sáng những pixel nào lên, mô hình sẽ tự tin hơn về lớp được dự đoán”.

Sẵn sàng cho câu hỏi

Nguyễn Trọng Bách — 23BI14057 — USTH ICT 2026