

Master Rehearsal Guide

Đồ án Phân loại Tồn thương Da bằng Học sâu
Tất cả những gì cần biết để bảo vệ thành công

Nguyễn Trọng Bách — 23BI14057

USTH ICT 2026

Mục lục

1	Cách dùng tài liệu này	2
2	Đồ án này là gì — 1 trang elevator pitch	2
3	Định nghĩa nền tảng	3
3.1	Học sâu (Deep Learning)	3
3.2	Pretrain — huấn luyện “từ đầu”	3
3.3	Fine-tune — “điều chỉnh nhỏ”	4
3.4	Đồ án này dùng cái nào?	4
4	Dữ liệu ISIC 2018 / HAM10000	4
4.1	7 lớp tổn thương	4
4.2	Mất cân bằng cực đoan	4
4.3	Stratified split 70/15/15	5
5	Tiền xử lý + Augmentation	5
5.1	Tiền xử lý cơ bản	5
5.2	Augmentation cho train (chỉ train, không val/test)	5
6	Weighted Random Sampler	5
6.1	Ý tưởng	6
6.2	Công thức	6
7	Mixup — “trộn 2 ảnh”	6
7.1	Công thức	6
8	CutMix — “cắt + dán patch”	7
8.1	Công thức	7
9	Label Smoothing — “làm mềm nhãn”	7
9.1	Công thức	8

10 Bốn kiến trúc mô hình	8
10.1 EfficientNet-B0 (5.3M tham số)	8
10.2 ResNet50 (25.6M tham số)	8
10.3 DenseNet121 (8.0M tham số)	8
10.4 Swin-Tiny (28.0M tham số, Vision Transformer)	9
11 Pipeline huấn luyện đầy đủ	9
11.1 Hàm mất mát	9
11.2 Optimizer AdamW	9
11.3 Cosine Annealing với Warmup	9
11.4 Siêu tham số	9
12 Ensemble bằng Soft Voting	9
12.1 Tại sao cần ensemble?	10
12.2 Công thức Soft Voting	10
12.3 Tại sao Soft Voting tốt hơn Hard Voting hay Stacking?	10
13 Multi-seed + McNemar (Tuần 1)	10
13.1 Tại sao multi-seed?	11
13.2 Kết quả 5 hạt giống	11
13.3 McNemar test — chứng minh thống kê	11
13.4 Tổ hợp qua 5 hạt giống bằng Fisher's method	12
14 Grad-CAM — khả diễn giải	12
14.1 Tại sao Grad-CAM xài được?	12
14.2 4 bước toán học	12
14.3 Target layer mỗi mô hình	12
14.4 Grad-CAM định lượng (4 chỉ số)	13
15 Các chỉ số đánh giá	13
15.1 Tại sao Accuracy không đủ?	13
15.2 Định nghĩa metric chính	13
16 Ablation Study	14
16.1 Phương pháp	14
16.2 Kết quả	14
16.3 3 phát hiện và 2 nghịch lý	14
17 Metadata fusion (Tuần 2) — vượt 90%	14
17.1 Ý tưởng	15

17.2	Vector metadata 19 chiều	15
17.3	Kiến trúc late fusion	15
17.4	Kết quả	15
17.5	Bug story FP16	15
18	OOD evaluation (Tuần 3) — trên ảnh smartphone	16
18.1	Tại sao OOD eval?	16
18.2	Mapping 6 PAD-UFES → 5 ISIC	16
18.3	Kết quả	16
19	So sánh với State-of-the-Art	16
20	Honest contribution — KHÔNG over-claim	17
21	10 câu hỏi khó nhất + cách trả lời	17
22	Defense kit checklist	18
22.1	Phần cứng	18
22.2	Software & demo	19
22.3	Backup plans	19
22.4	1 tiếng trước	19
23	Tóm tắt một trang (in mang theo)	20

1. Cách dùng tài liệu này

Định hướng

Tài liệu này là **một file duy nhất** bạn cần đọc khi rehearsal. Nó cover:

- Mọi kỹ thuật trong đề án — giải thích kiểu *trẻ con* trước, sau đó nâng lên *toán học chính xác*.
- Mọi con số cập nhật tới Tuần 3 (multi-seed, metadata fusion, OOD).
- Mỗi khái niệm có *ví dụ cụ thể bằng số*.
- 10 câu hỏi khó nhất hội đồng có thể hỏi + cách trả lời.
- Checklist defense-day.
- Tóm tắt một trang để in.

Quy ước hộp màu:

Giải thích kiểu trẻ con

Hộp xanh lá — giải thích bằng ngôn ngữ đời thường, không công thức. Bạn nên hiểu *cái này* trước khi đi vào toán.

Ví dụ

Hộp vàng — ví dụ tính toán cụ thể bằng số thật của đề án. Đây là cách trả lời “cho em xin ví dụ” khi hội đồng hỏi.

Hộp xanh dương — ý chính / hiểu sâu

Bullet quan trọng nhất của một section. Đọc lại trước defense.

Hội đồng có thể hỏi

Hộp cam — câu hỏi giả định của hội đồng kèm câu trả lời mẫu.

Lịch trình đọc đề xuất:

- Lần 1 (90 phút): đọc tuần tự từ section 2 đến section 22.
- Lần 2 (45 phút): chỉ đọc hộp *xanh dương* và *cam*.
- Lần 3 (15 phút sáng defense): đọc section 23 (tóm tắt một trang).

2. Đề án này là gì — 1 trang elevator pitch

Bài toán. Cho 1 ảnh dermoscopy (ảnh soi da bằng kính phóng đại), dự đoán nó thuộc **1 trong 7 loại tổn thương**: akiec, bcc, bkl, df, mel, nv, vasc. Trong đó mel (melanoma — ung thư hắc tố) là lớp **nguy hiểm nhất**.

Dữ liệu. ISIC 2018 Task 3 / HAM10000 — 10.015 ảnh, mất cân bằng cực đoan (NV chiếm 67%, DF chỉ 1.1%, tỉ lệ **58:1**).

Phương pháp. Fine-tune 4 mô hình pretrained ImageNet (*EfficientNet-B0*, *ResNet50*, *DenseNet121*, *Swin-Tiny*) trên ISIC 2018, kết hợp bằng **soft-voting ensemble**, mở rộng bằng **metadata bệnh nhân** (tuổi, giới, vị

trí giải phẫu).

Kết quả headline:

- Mô hình đơn tốt nhất (hạt giống 42): EfficientNet-B0 — Acc 88.36%, F1 0.831.
- Ensemble chỉ-ảnh (1 hạt giống): Acc **89.49%**, F1 **0.845**, AUC **0.980**.
- Ensemble chỉ-ảnh (5 hạt giống): Acc **89.93 ± 0.66%**, F1 **0.852 ± 0.010**, AUC **0.982 ± 0.001**.
- Ensemble + metadata fusion: Acc **90.49%**, F1 **0.873**, AUC **0.984** — vượt Pacheco & Krohling 2020.
- OOD trên PAD-UFES-20 (ảnh smartphone, zero-shot): Acc **32.46%** — drop 56 pp, chi phí chuẩn của transfer dermoscopy → smartphone.

Khả diễn giải. Grad-CAM (Selvaraju 2017) + định lượng 4 chỉ số: $\text{focus_ratio} > 0.6$ và $\text{peak_distance} < 0.2$ trên cả 4 mô hình $\Rightarrow$ mô hình thật sự nhìn vào tổn thương, không phải nhiễu.

Sản phẩm. Prototype Streamlit (app.py) cho phép bác sĩ upload ảnh, nhận chẩn đoán + heatmap real-time.

Thông điệp một câu

Một pipeline điều chuẩn cẩn thận, ensemble đa kiến trúc, + metadata bệnh nhân có thể đạt 90%+ trên ISIC 2018, vượt một số công trình SOTA — nhưng deploy thực tế trên ảnh smartphone vẫn cần domain adaptation (drop 56 pp).

3. Định nghĩa nền tảng

3.1. Học sâu (Deep Learning)

Giải thích kiểu trẻ con

Học sâu = mạng nơ-ron có *nhiều lớp* xếp chồng. Mỗi lớp nhận output của lớp trước, biến đổi thành biểu diễn “trừu tượng hơn”. Với ảnh: lớp đầu nhìn *cạnh*, lớp giữa nhìn *bộ phận*, lớp cuối nhìn *khái niệm*.

Toán: cho dữ liệu (x_i, y_i) và tham số θ , mạng học bằng gradient descent:

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\theta}(x_i), y_i).$$

3.2. Pretrain — huấn luyện “từ đầu”

Giải thích kiểu trẻ con

Pretrain = bắt mạng học từ con số 0 trên một tập *rất lớn*. Mục tiêu: dạy mạng cách “nhìn” nói chung. Ví dụ: dạy mạng phân biệt mèo, chó, xe hơi — chưa biết gì về da liễu.

Pretrain trên ImageNet

ImageNet-1K có 1,28 triệu ảnh, 1000 lớp. Huấn luyện EfficientNet-B0 trên ImageNet mất *hàng tuần* trên nhiều GPU. Kết quả: file weights θ_{pre} — mạng “biết nhìn ảnh” dù chưa biết gì về da.

3.3. Fine-tune — “điều chỉnh nhỏ”

Giải thích kiểu trẻ con

Fine-tune = lấy mạng đã pretrain, sửa output cho task mới, rồi train tiếp trên data nhỏ hơn. Giống như: bạn đã biết tiếng Anh, giờ học tiếng Anh *y khoa* — không cần học lại từ A-Z, chỉ học thêm thuật ngữ chuyên ngành.

Fine-tune EB0 cho ISIC 2018

1. Tải θ_{pre} (ImageNet weights) từ timm.
2. Thay classifier head: `Linear(1280, 1000) → Linear(1280, 7)` (khởi tạo random).
3. Train toàn bộ trên 7.010 ảnh ISIC với LR nhỏ $3e-4$ trong 50 epoch.

Khi nào dùng cái nào?

Train từ đầu cần > 100K ảnh, mất tuần GPU — không khả thi trên 10K ảnh ISIC. **Fine-tune** cần vài nghìn ảnh, mất phút-giờ — chính là cái đề án dùng.

3.4. Đề án này dùng cái nào?

Đề án dùng fine-tune. Tải weights ImageNet sẵn từ timm, không tự pretrain. Code thực tế:

Listing 1: src/models/build_model.py

```
1 import timm
2 def build_model(model_cfg: dict):
3     model = timm.create_model(
4         model_cfg['name'],          # "tf_efficientnet_b0", "resnet50", ...
5         pretrained=True,           # Load ImageNet weights
6         num_classes=7,             # thay head: 1000 -> 7
7         drop_rate=0.3,             # dropout trước classifier
8     )
9     return model
```

Hội đồng có thể hỏi

Q: Em pretrain hay fine-tune?

A: Fine-tune. Em không có data để pretrain (cần triệu ảnh). Em tải weights ImageNet pretrained từ timm, thay classifier head từ 1000 lớp ImageNet về 7 lớp ISIC, rồi train toàn bộ mạng trên ISIC với learning rate nhỏ.

4. Dữ liệu ISIC 2018 / HAM10000

4.1. 7 lớp tổn thương

4.2. Mất cân bằng cực đoan

Giải thích kiểu trẻ con

Lớp đông nhất (NV: 4.693 ảnh) so với lớp ít nhất (DF: 81 ảnh) = tỉ lệ **58:1**. Tức là nếu chia bài thi trong 59 ảnh ngẫu nhiên có 58 NV và 1 DF. Mất cân bằng kiểu này làm mọi mô hình tự nhiên thiên về NV.

Mã	Tên đầy đủ	Train	Val	Test	Tổng
nv	Melanocytic Nevus (nốt ruồi)	4.693	1.006	1.006	6.705
mel	Melanoma (ung thư hắc tố)	779	167	167	1.113
bkl	Benign Keratosis-like	769	165	165	1.099
bcc	Basal Cell Carcinoma	360	77	77	514
akiec	Actinic Keratosis (tiền ung thư)	229	49	49	327
vasc	Vascular Lesion (mạch máu)	99	21	22	142
df	Dermatofibroma (u xơ)	81	17	17	115
Tổng		7.010	1.502	1.503	10.015

Tại sao mất cân bằng nguy hiểm?

Mô hình *lười* có thể dự đoán “NV cho mọi ảnh” và đạt **67% accuracy** mà không học gì cả — nhưng bỏ sót 100% melanoma. Vì vậy ta dùng **Macro F1** (trung bình F1 *không* trọng số 7 lớp), không phải Accuracy, làm metric chính.

4.3. Stratified split 70/15/15

Giải thích kiến thức con

Stratified = chia dữ liệu giữ nguyên tỉ lệ 7 lớp trong cả train/val/test. Nếu chia ngẫu nhiên thuần túy, có nguy cơ val set không có DF nào (chỉ 17 ảnh trong 10K).

5. Tiền xử lý + Augmentation

5.1. Tiền xử lý cơ bản

Mọi ảnh đều được:

- **Resize 224×224** — kích thước chuẩn ImageNet pretrained.
- **ToTensor** — pixel $[0, 255] \rightarrow [0, 1]$.
- **Normalize** bằng mean/std ImageNet:

$$x' = \frac{x - \mu_{\text{ImageNet}}}{\sigma_{\text{ImageNet}}}, \quad \mu = (0.485, 0.456, 0.406), \quad \sigma = (0.229, 0.224, 0.225).$$

Giải thích kiến thức con

Tại sao dùng mean/std ImageNet? Mô hình pretrained đã “quen” với phân phối input chuẩn hóa kiểu đó. Nếu normalize sai cách, input lệch khỏi distribution training $\Rightarrow$ mô hình hoảng loạn.

5.2. Augmentation cho train (chỉ train, không val/test)

6. Weighted Random Sampler

Phép biến đổi	Tham số	Lý do
RandomResizedCrop	scale 0.85–1.0	Bất biến scale
HorizontalFlip	$p = 0.5$	Ảnh da đối xứng
VerticalFlip	$p = 0.5$	Không có “lên/xuống” cố định
Rotation	$\pm 90^\circ$	Bất biến xoay
ColorJitter	$b/c/s/h = 0.25$	Robust với thiết bị chụp
GaussianBlur	$p = 0.1$	Robust với độ nét
RandomErasing	$p = 0.1$	Robust với che khuất

6.1. Ý tưởng

Giải thích kiểu trả còn

DataLoader bình thường chọn ảnh đều nhau $\rightarrow$ trong 1 batch toàn NV. Weighted Sampler gán *trọng số* cao cho lớp hiếm $\rightarrow$ DataLoader chọn DF thường xuyên hơn $\rightarrow$ mỗi batch cân bằng 7 lớp.

6.2. Công thức

$$w_c = \frac{1}{n_c} \quad (\text{hoặc chuẩn hóa}) \quad w_c = \frac{N}{C \cdot n_c}$$

Trọng số 7 lớp ISIC train

$N = 7.010, C = 7$:

Lớp	n_c	w_c
nv	4.693	0.213
mel	779	1.286
bkl	769	1.303
bcc	360	2.782
akiec	229	4.373
vasc	99	10.117
df	81	12.365

Hệ quả: 1 ảnh DF được chọn với xác suất gấp $12.365/0.213 \approx 58\times$ so với 1 ảnh NV. Sau khi sampling, mỗi mini-batch xấp xỉ cân bằng.

7. Mixup — “trộn 2 ảnh”

Giải thích kiểu trả còn

Mixup = lấy 2 ảnh khác nhau, “trộn” chúng theo tỉ lệ ngẫu nhiên, trộn cả nhãn theo cùng tỉ lệ. Ép mô hình hoạt động *tuyến tính* giữa các mẫu $\rightarrow$ tránh memorize.

7.1. Công thức

Cho 2 mẫu (x_i, y_i) và (x_j, y_j) , lấy $\lambda \sim \text{Beta}(\alpha, \alpha)$ với $\alpha = 0.2$:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda) y_j.$$

Mixup melanoma + nốt ruồi

- x_i = ảnh melanoma, $y_i = [0, 0, 0, 0, \mathbf{1}, 0, 0]$ (mel)
- x_j = ảnh nốt ruồi, $y_j = [0, 0, 0, 0, 0, \mathbf{1}, 0]$ (nv)
- $\lambda = 0.7$ ngẫu nhiên.

Ảnh trộn: $\tilde{x} = 0.7 x_i + 0.3 x_j$ — ảnh mel “rõ 70%” chồng lên ảnh nv “mờ 30%”.

Nhãn trộn: $\tilde{y} = [0, 0, 0, 0, \mathbf{0.7}, \mathbf{0.3}, 0]$.

Mô hình phải dự đoán xác suất mel gần 0.7 và nv gần 0.3.

Ablation: Mixup quan trọng nhất

Bỏ Mixup/CutMix khỏi pipeline làm Macro F1 **giảm 4.51%** — thành phần đóng góp lớn nhất. Vì với chỉ 81 ảnh DF train, không có Mixup mô hình sẽ *nhớ thuộc lòng* 81 ảnh đó trong vài epoch đầu.

8. CutMix — “cắt + dán patch”

Giải thích kiểu trộn con

CutMix khác Mixup: thay vì trộn toàn ảnh (kiểu mờ chồng), CutMix *cắt một patch vuông* từ ảnh j và *dán đè* lên ảnh i . Nhãn lai theo *diện tích patch*.

8.1. Công thức

$$\tilde{x} = M \odot x_i + (1 - M) \odot x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda) y_j,$$

với $M \in \{0, 1\}^{H \times W}$ là mask bounding box, $\lambda = 1 - \frac{\text{diện tích patch}}{H \cdot W}$.

CutMix patch 80×80

- x_i = ảnh nốt ruồi 224×224, y_i = nv.
- x_j = ảnh melanoma 224×224, y_j = mel.
- Sample bounding box ngẫu nhiên 80×80 ở góc trên-trái.

Ảnh trộn: ảnh nốt ruồi với vùng 80×80 được thay bằng pixel từ melanoma.

$\lambda: 1 - 80 \cdot 80 / (224 \cdot 224) = 1 - 0.128 = 0.872$.

Nhãn trộn: $[0, 0, 0, 0, \mathbf{0.128}, \mathbf{0.872}, 0]$.

9. Label Smoothing — “làm mềm nhãn”

Giải thích kiểu trộn con

One-hot label nói: “*chắc chắn* 100% là MEL, 0% là mọi lớp khác”. Label Smoothing thay bằng “**91%** là MEL, mỗi lớp khác 1.5%”. Ngăn mô hình quá tự tin.

9.1. Công thức

$$y_k^{\text{LS}} = (1 - \varepsilon) \mathbb{I}[k = c] + \frac{\varepsilon}{C}, \quad \varepsilon = 0.1, C = 7.$$

Smoothing nhãn MEL

$y_{\text{onehot}} = [0, 0, 0, 0, 1, 0, 0]$ (mel).

Với $\varepsilon = 0.1, C = 7$: phần “đúng” giảm còn $1 - 0.1 = 0.9$, phần 0.1 rải đều 7 lớp: $0.1/7 \approx 0.0143$.

$$y^{\text{LS}} = [0.0143, 0.0143, 0.0143, 0.0143, 0.9143, 0.0143, 0.0143].$$

Kiểm tra: $0.9143 + 6 \cdot 0.0143 = 1.000$. $\square$

Nghịch lý đã quan sát

Bỏ Label Smoothing làm AUC **tăng** ($0.952 \rightarrow 0.967$) nhưng Macro F1 **giảm** 3.11%. Hard target $\Rightarrow$ probability ranking sắc nét (AUC cao) nhưng ranh giới quyết định cứng sai nhiều ở vùng biên (F1 thấp).

10. Bốn kiến trúc mô hình

10.1. EfficientNet-B0 (5.3M tham số)

Giải thích kiến trúc con

Mô hình *nhỏ nhất* trong 4 mô hình. Ý tưởng: tăng đồng thời *độ sâu* (số layer), *độ rộng* (số channel), *độ phân giải* (image size) bằng cùng một hệ số scaling — gọi là “compound scaling”. Có Squeeze-and-Excitation (SE) blocks học global context theo kênh.

10.2. ResNet50 (25.6M tham số)

Giải thích kiến trúc con

Kiến trúc *kinh điển*. Ý tưởng cốt lõi: residual connection $f(x) = F(x) + x$. Cho phép mạng rất sâu (50+ layer) vẫn huấn luyện được mà không bị vanishing gradient.

10.3. DenseNet121 (8.0M tham số)

Giải thích kiến trúc con

Mỗi layer nhận concatenation của *tất cả* layer trước đó — gọi là dense connectivity. Tận dụng features đã học, giảm số tham số.

10.4. Swin-Tiny (28.0M tham số, Vision Transformer)

Giải thích kiến trúc

Mô hình *khác hẳn* 3 CNN trên. Dùng *self-attention* thay convolution. Chia ảnh thành các cửa sổ nhỏ (window), tính attention trong window, rồi *dịch cửa sổ* để các vùng giao tiếp với nhau. Hierarchical 4 stage.

Tại sao chọn 4 kiến trúc đa dạng?

3 CNN (EB0, RN50, DN121) + 1 Transformer (Swin) $\Rightarrow$ *lỗi không tương quan*. CNN focus local, Swin focus global. Khi ensemble, lỗi của mô hình này không trùng lỗi mô hình kia $\Rightarrow$ trung bình xác suất *thật sự* cải thiện.

11. Pipeline huấn luyện đầy đủ

11.1. Hàm mất mát

Cross-entropy với label smoothing:

$$\mathcal{L}_{\text{CE}}(p, y) = - \sum_{k=1}^C y_k^{\text{LS}} \log p_k.$$

11.2. Optimizer AdamW

Giải thích kiến trúc

Adam = optimizer “thông minh” tự điều chỉnh learning rate cho từng tham số. AdamW = Adam với weight decay *đúng cách* (áp trực tiếp lên tham số, không vào gradient). Phổ biến nhất hiện nay.

$$\theta_t = \theta_{t-1} - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda \theta_{t-1} \right).$$

11.3. Cosine Annealing với Warmup

Giải thích kiến trúc

Warmup: LR tăng từ ~ 0 lên đỉnh trong 3-5 epoch đầu — tránh phá weights pretrained ngay đầu.
Cosine: LR giảm dần theo đường cosine từ đỉnh xuống min — hội tụ êm về cuối.

11.4. Siêu tham số

Tại sao Swin khác?

Transformer thiếu inductive bias của CNN $\Rightarrow$ cần **LR thấp** để không phá pretrained attention weights, **weight decay cao** để hạn chế overfit (28M tham số trên 7K ảnh = tỉ lệ rất dễ overfit).

12. Ensemble bằng Soft Voting

	EB0	RN50	DN121	Swin
Learning rate	3e-4	3e-4	2.5e-4	1e-4
Weight decay	1e-3	1e-3	1e-3	5e-2
Warmup epochs	3	3	3	5
Max epochs	50	50	50	50
Batch size	16	16	16	16
Mixup / CutMix α	0.2/1.0	0.2/1.0	0.2/1.0	0.2/1.0
Label smoothing ε	0.1	0.1	0.1	0.1

12.1. Tại sao cần ensemble?

Giải thích kiểu trẻ con

1 mô hình hay sai ở *một số ảnh nhất định*. Mô hình khác sai ở *ảnh khác*. Trung bình 4 mô hình $\Rightarrow$ lỗi cá nhân bị triệt tiêu, giữ lại sự đồng thuận.

12.2. Công thức Soft Voting

Với $M = 4$ mô hình, mỗi mô hình m cho vector xác suất $p_m(x) \in [0, 1]^7$:

$$\bar{p}(x) = \frac{1}{M} \sum_{m=1}^M p_m(x), \quad \hat{y} = \arg \max_c \bar{p}_c(x).$$

Soft voting trên 1 ảnh test thật

4 mô hình cho 4 vector xác suất cho 7 lớp (akiec, bcc, bkl, df, **mel**, nv, vasc):

	akiec	bcc	bkl	df	mel	nv	vasc
EB0	0.02	0.03	0.05	0.01	0.65	0.22	0.02
RN50	0.03	0.05	0.08	0.01	0.55	0.26	0.02
DN121	0.02	0.03	0.06	0.01	0.62	0.24	0.02
Swin	0.04	0.04	0.05	0.01	0.48	0.36	0.02
TB	0.028	0.038	0.060	0.010	0.575	0.270	0.020

Argmax: mel với xác suất ensemble 57.5%. Swin “chưa chắc chắn” (48%) nhưng các CNN đẩy lên — kết quả ensemble vẫn vững.

12.3. Tại sao Soft Voting tốt hơn Hard Voting hay Stacking?

- **Hard voting** (mỗi mô hình argmax rồi vote): mất thông tin xác suất. Không phân biệt được “cả 4 chắc MEL” và “2 MEL 51%, 2 NV 49%”.
- **Stacking** (meta-learner học trọng số ensemble): cần val set thứ hai, dễ overfit trên data nhỏ.
- **Soft voting**: đơn giản, ổn định, không cần train thêm — đã đạt 89.49% in-distribution, không có headroom rõ ràng để stacking phá được.

13. Multi-seed + McNemar (Tuần 1)

13.1. Tại sao multi-seed?

Giải thích kiểu trả lời

1 hạt giống = 1 lần “tung xúc xắc” tốt — có thể may. Hội đồng sẽ hỏi: “làm sao biết 89.49% không phải may?” Trả lời: chạy lại 5 lần với 5 hạt giống khác nhau, báo cáo *trung bình ± độ lệch chuẩn*.

13.2. Kết quả 5 hạt giống

Mô hình	Accuracy	Macro F1	Macro AUC
EfficientNet-B0	87.31 ± 1.32%	0.814 ± 0.022	0.965 ± 0.006
ResNet50	86.31 ± 0.57%	0.792 ± 0.011	0.949 ± 0.003
DenseNet121	85.62 ± 2.42%	0.797 ± 0.025	0.960 ± 0.004
Swin-Tiny	88.33 ± 1.96%	0.839 ± 0.030	0.966 ± 0.008
Ensemble	89.93 ± 0.66%	0.852 ± 0.010	0.982 ± 0.001

3 phát hiện quan trọng

- (1) 89.49% (1 hạt giống) nằm trong 1σ của trung bình 89.93% $\Rightarrow$ **không lucky, robust**.
- (2) Swin-Tiny mới là mô hình đơn mạnh nhất khi average qua seeds (88.33% > EB0 87.31%). Hạt giống 42 là pha xui của Swin.
- (3) Std của ensemble cực nhỏ (Acc 0.66%, AUC 0.001) $\Rightarrow$ soft voting hấp thụ phương sai cấp hạt giống.

13.3. McNemar test — chứng minh thống kê

Giải thích kiểu trả lời

McNemar = kiểm định thống kê so sánh 2 classifier trên *cùng tập test*. Đếm: bao nhiêu ảnh A đúng B sai vs. bao nhiêu ảnh A sai B đúng. Nếu chênh lệch lớn $\Rightarrow$ classifier này *thực sự* tốt hơn classifier kia, không phải ngẫu nhiên.

Công thức McNemar (có continuity correction):

$$\chi^2 = \frac{(|n_{ab} - n_{ba}| - 1)^2}{n_{ab} + n_{ba}}, \quad p = \chi^2_{1-\text{survival}}(\chi^2).$$

McNemar: Swin vs. Ensemble, seed 42

1503 ảnh test:

- $n_{ab} = 33$ (Swin đúng, ensemble sai)
- $n_{ba} = 93$ (Swin sai, ensemble đúng)
- $\chi^2 = (|33 - 93| - 1)^2 / (33 + 93) = 59^2 / 126 = 27.63$
- $p = 1.47 \times 10^{-7}$

$p \ll 0.05 \Rightarrow$ ensemble **thực sự** hơn Swin, không phải ngẫu nhiên.

13.4. Tổ hợp qua 5 hạt giống bằng Fisher's method

$$\chi^2_{\text{combined}} = -2 \sum_{i=1}^k \log p_i, \quad df = 2k.$$

Mô hình đơn vs. Ensemble	Ensemble thắng	Fisher combined p
EfficientNet-B0	5/5	5.3×10^{-18}
ResNet50	5/5	4.5×10^{-31}
DenseNet121	5/5	6.7×10^{-39}
Swin-Tiny (mạnh nhất)	5/5	1.2×10^{-7}

14. Grad-CAM — khả diễn giải

14.1. Tại sao Grad-CAM xài được?

Giải thích kiểu trẻ con

Mô hình nói “MEL 90%” nhưng *tại sao?* Grad-CAM tạo bản đồ nhiệt: chỗ nào càng đỏ thì mô hình càng dựa vào để quyết định. Nếu mô hình nhìn vào tổn thương $\Rightarrow$ tin cậy. Nếu nhìn vào lông/ruler/góc ảnh $\Rightarrow$ chưa chắc tin được.

14.2. 4 bước toán học

Cho ảnh x , lớp mục tiêu c , feature map $A \in \mathbb{R}^{K \times H \times W}$ tại layer conv cuối:

Bước 1 — forward + backward:

$$y^c = f_{\theta}(x)[c], \quad \frac{\partial y^c}{\partial A_{ij}^k}.$$

Bước 2 — trọng số kênh (GAP gradient):

$$\alpha_c^k = \frac{1}{HW} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}.$$

Bước 3 — heatmap (ReLU):

$$L_c = \text{ReLU} \left(\sum_k \alpha_c^k A^k \right).$$

Bước 4: up-sample về 224×224 , normalize $[0, 1]$, overlay colormap JET.

14.3. Target layer mỗi mô hình

Mô hình	Target layer	Shape
EfficientNet-B0	<code>model.blocks[-1][-1]</code>	(320, 7, 7)
ResNet50	<code>model.layer4[-1]</code>	(2048, 7, 7)
DenseNet121	<code>model.features.norm5</code>	(1024, 7, 7)
Swin-Tiny	<code>model.layers[-1].blocks[-1].norm2</code>	(49, 768)

Bài học sai lầm — model.bn2 story

Ban đầu dùng model.bn2 của EfficientNet (BatchNormAct2d + SiLU). $\text{SiLU}(x) \approx 0$ với $x < 0$, sau BN khoảng 50% activation về 0 $\Rightarrow$ chỉ 18% pixel có activation $\Rightarrow$ heatmap *xanh đồng đều*, không tập trung.

Chuyển sang blocks[-1][-1]: 51% pixel active, heatmap *khoanh đúng tổn thương*. **Nếu không có metric định lượng, sai lầm này trượt qua mắt thường.**

14.4. Grad-CAM định lượng (4 chỉ số)

focus_ratio	Tỉ lệ activation nằm trong lesion mask (Otsu). Cao = focus đúng.
peak_distance	Khoảng cách peak activation $\rightarrow$ centroid lesion. Thấp = focus đúng tâm.
entropy	Shannon entropy heatmap. Thấp = focus sắc nét.
coverage_75	% diện tích chứa top-25% activation. Thấp = compact.

Cả 4 mô hình đều đạt $\text{focus_ratio} > 0.6$ và $\text{peak_distance} < 0.2$ trên test set.

15. Các chỉ số đánh giá

15.1. Tại sao Accuracy không đủ?

Ghi chú hiệu ứng

Trên data mất cân bằng 58:1, mô hình “đoán NV cho mọi ảnh” đạt Accuracy 67% mà bỏ sót 100% melanoma. Vậy Accuracy là metric *lừa dối*.

15.2. Định nghĩa metric chính

Metric	Công thức	Ý nghĩa
Accuracy	$\sum TP_c / N$	Đúng tổng thể (lệch với imbalance)
Macro F1	$\frac{1}{C} \sum F1_c$	F1 trung bình không trọng số — METRIC CHÍNH
Weighted F1	$\sum F1_c \cdot n_c / N$	F1 trọng số theo cỡ lớp
Macro AUC	$\frac{1}{C} \sum AUC_c$	Khả năng xếp hạng xác suất
Cohen's κ	$(P_o - P_e) / (1 - P_e)$	Đồng thuận vs. random
MCC	cân bằng nhất	Dùng cả 4 ô confusion
Sensitivity	$TP / (TP + FN)$	Recall — phát hiện đúng positive
Specificity	$TN / (TN + FP)$	Xác định đúng negative

F1 melanoma của ensemble

167 ảnh MEL thật trong test. Ensemble dự đoán “MEL” 166 ảnh, đúng 124 ảnh.

$$TP = 124, \quad FP = 166 - 124 = 42, \quad FN = 167 - 124 = 43$$

$$\text{Precision} = 124/166 = 0.747$$

$$\text{Recall} = 124/167 = 0.740$$

$$F1 = \frac{2 \cdot 0.747 \cdot 0.740}{0.747 + 0.740} = \mathbf{0.744}$$

16. Ablation Study

16.1. Phương pháp

Giải thích hiệu ứng

Lần lượt *xóa 1 thành phần* của pipeline, giữ nguyên còn lại. Đo mức sụt giảm Macro F1. Thành phần xóa đi mà sụt nhiều = thành phần quan trọng nhất.

16.2. Kết quả

Cấu hình	Acc	Macro F1	AUC	Δ F1
Full pipeline	0.8836	0.8311	0.9522	—
– Mixup & CutMix	0.8589	0.7860	0.9486	−0.0451
– Label Smoothing	0.8776	0.8000	0.9674	−0.0311
– Weighted Sampler	0.8762	0.8041	0.9521	−0.0270
– Advanced Aug	0.8896	0.8204	0.9664	−0.0107

16.3. 3 phát hiện và 2 nghịch lý

1. Mixup/CutMix quan trọng nhất (−4.51% F1). Với 81 ảnh DF train, không Mixup mô hình memorize sample hiếm.

2. Nghịch lý Label Smoothing. Bỏ LS làm AUC *tăng* (0.952 → 0.967) nhưng F1 *giảm* 3.11%. Hard target ⇒ ranking sắc (AUC cao) nhưng boundary cứng sai ở MEL/NV/BKL (F1 thấp).

3. Nghịch lý Augmentation. Bỏ aug mạnh thậm chí làm Accuracy *nhỉnh hơn* (88.96% > 88.36%) vì model dễ fit NV. Nhưng Macro F1 giảm — minority bị bỏ rơi.

Bài học cốt lõi

Đóng góp lớn nhất **không phải kiến trúc lớn hơn** mà là **regularization tốt hơn**. Mixup/CutMix + LS + Weighted Sampler đóng góp tổng cộng **~10% F1** — nhiều hơn khoảng cách giữa các kiến trúc.

17. Metadata fusion (Tuần 2) — vượt 90%

17.1. Ý tưởng

Ghi chú liên hệ

Ảnh không đủ. Bác sĩ luôn cân nhắc tuổi, giới, vị trí trước khi chẩn đoán. Một u màu nâu trên lưng người 30 tuổi khác hẳn cùng u đó trên mặt người 75 tuổi. Pipeline cũ bỏ qua. Tuần 2 em thêm 19-dim vector metadata vào pipeline.

17.2. Vector metadata 19 chiều

- 1 chiều: tuổi đã chuẩn hóa (mean 51.86, std 16.97, missing $\rightarrow$ mean).
- 3 chiều: one-hot giới (male / female / unknown).
- 15 chiều: one-hot vị trí giải phẫu (abdomen, back, chest, ear, face, foot, ..., unknown).

17.3. Kiến trúc late fusion

$$\text{logits} = \text{Linear}(\text{Concat}(f_{\text{img}}(x), \text{MLP}(\text{meta})))$$

MLP: $19 \rightarrow 64 \rightarrow 32$ với ReLU và dropout 0.1.

17.4. Kết quả

Mô hình	Acc chỉ-ảnh	Acc +metadata	Δ Acc	F1 +meta
EfficientNet-B0	0.8796	0.8337	-4.6 pp	0.768
ResNet50	0.8636	0.8782	+1.5 pp	0.810
DenseNet121	0.8543	0.8550	+0.1 pp	0.793
Swin-Tiny	0.8490	0.8982	+4.9 pp	0.871
Ensemble	0.8949	0.9049	+1.0 pp	0.8728

3 phát hiện đột phá

(1) **Swin + metadata đơn lẻ vượt ensemble chỉ-ảnh!** 89.82% > 88.89%. Self-attention tích hợp metadata hiệu quả hơn CNN trong setting này.

(2) **EB0 mất 4.6 pp.** Model nhỏ (5.3M) không đủ chỗ cho meta encoder mà không hi sinh image features.

(3) **Ensemble đạt 90.49% / 0.873 / 0.984 AUC** — vượt Pacheco & Krohling 2020 (89.0% / 0.83), là image+metadata fusion mạnh nhất công bố trên ISIC 2018.

17.5. Bug story FP16

Bug “AMP FP16 softmax NaN” — bài học

Ban đầu train_meta.py chạy softmax dưới AMP autocast $\rightarrow$ FP16 probability. Khi save vào CSV với pandas .round(6), FP16 không đủ precision $\rightarrow$ **NaN toàn bộ**. Per-model metrics OK (compute in-memory) nhưng ensemble = NaN $\rightarrow$ accuracy 3.26% (dưới random!).

Fix: cast logits.float() trước softmax. Bài học: *luôn* dùng float32 cho probabilities khi save xuống disk.

18. OOD evaluation (Tuần 3) — trên ảnh smartphone

18.1. Tại sao OOD eval?

Giải thích kiến thức con

Test cùng phân phối train (ISIC 2018 dermoscopy) không chứng minh được mô hình triển khai được trên ảnh thực tế. Em test zero-shot trên 2.298 ảnh smartphone PAD-UFES-20 (Brazil) — modality khác hẳn dermoscopy.

18.2. Mapping 6 PAD-UFES → 5 ISIC

- ACK → akiec
- SCC → akiec (Pacheco cluster với AKIEC)
- BCC → bcc
- SEK → bkl
- NEV → nv
- MEL → mel

18.3. Kết quả

Lớp	Precision	Recall	F1	AUC	Support
akiec	0.543	0.145	0.229	0.614	922
bcc	0.611	0.421	0.499	0.733	845
bkl	0.175	0.268	0.212	0.633	235
mel	0.057	0.308	0.097	0.684	52
nv	0.258	0.725	0.380	0.811	244
Accuracy 32.46% (vs. 88.89% in-distribution: −56 pp)					

Độc đúng kết quả OOD

Drop 56 pp KHÔNG phải thảm họa. Là chi phí chuẩn của transfer zero-shot dermoscopy → smartphone (literature cùng range 50-60 pp).

- AUC theo lớp giữ 0.61–0.81 ⇒ probability ranking transfer được *một phần*, mô hình không random.
- NV recall 0.72 ⇒ prior collapse về lớp đa số ISIC (kinh điển).
- MEL precision 0.06 ⇒ mô hình gọi MEL quá thường xuyên ⇒ nguy hiểm nếu deploy không adapt.

Kết luận trung thực: pipeline chưa sẵn sàng cho ảnh smartphone consumer. Đóng khoảng cách = **bài tập kỹ thuật** (domain adaptation, fine-tune in-domain, style transfer), *không phải bí ẩn nghiên cứu*.

19. So sánh với State-of-the-Art

Công trình	Năm	Phương pháp	Acc	Macro F1
Codella et al.	2018	ResNet-152	85.9	0.78
Gessert (winner ISIC)	2018	Ensemble EB_n + SENet	88.5	0.82
Mahbod et al.	2020	Multi-scale CNN ensemble	88.7	0.83
Pacheco & Krohling	2020	RN50 + metadata fusion	89.0	0.83
Đồ án (chỉ ảnh)	2026	4-model ensemble, 5 seeds	89.93 ± 0.66	0.852 ± 0.010
Đồ án (+meta)	2026	4-model + metadata	90.49	0.873

20. Honest contribution — KHÔNG over-claim

Phải nói thẳng ở defense

Không có kỹ thuật nào trong đồ án là MỚI. Mọi thành phần đều có literature trước:

- Pacheco-style metadata fusion = Pacheco & Krohling 2020 y hết.
- PAD-UFES-20 OOD = chính Pacheco phát hành dataset.
- Soft voting, Mixup, CutMix, Label Smoothing = chuẩn industry.
- Ensemble CNN+Transformer = đã có nhiều paper 2022-2024.

Đóng góp THỰC SỰ:

1. **Tích hợp minh bạch** — code mở, configs YAML, 5 seeds tái lập, study guide đầy đủ. Hiếm ở SOTA.
2. **Grad-CAM định lượng** — focus_ratio, peak_distance đo trên test set. Hầu hết paper chỉ qualitative.
3. **Statistical robustness** — multi-seed + McNemar Fisher-combined. Đa số paper ISIC chỉ 1 seed.
4. **OOD honest reporting** — drop 56 pp công khai. Nhiều paper giấu OOD failure.
5. **Vượt nhẹ Pacheco 2020** — 90.49% vs 89.0% nhờ ensemble Transformer + CNN. Đây là *increment*, không phải *innovation*.

21. 10 câu hỏi khó nhất + cách trả lời

Q1: Tại sao soft voting mà không stacking?

3 lý do: (1) Stacking cần val thứ hai → overfit trên data nhỏ. (2) Hard voting mất thông tin xác suất. (3) Soft voting đã đạt 89.49%, McNemar $p < 10^{-7}$, không có headroom để stacking phá được.

Q2: Làm sao biết Grad-CAM là “đúng”?

Em đo 4 chỉ số định lượng: focus_ratio, peak_distance, entropy, coverage_75. Cả 4 mô hình đạt focus_ratio > 0.6 và peak_distance < 0.2. Em phát hiện bug model.bn2 nhờ định lượng — nếu chỉ nhìn heatmap thì sai lầm này đã trượt qua.

Q3: Macro F1 vs balanced accuracy khác gì?

Balanced accuracy = mean recall theo lớp → chỉ phạt false negative. Macro F1 = mean F1 → phạt cả false positive. Em chọn F1 vì lâm sàng cả 2 loại lỗi đều có chi phí (bỏ sót MEL nguy hiểm, báo động giả gây sinh thiết không cần).

Q4: Tại sao Swin overfit nhanh?

(1) Thiếu inductive bias — Transformer học cả locality và translation invariance từ data. (2) 28M tham số / 7K ảnh = $4.000\times$ — cực dễ overfit. (3) Self-attention bậc 2 dễ memorize cấu trúc cụ thể. Đã đổi pho: LR $1e-4$, weight decay $5e-2$, warmup 5 epoch.

Q5: Ảnh ngoài 7 lớp (mụn, sẹo) thì sao?

Mô hình *b buộc phải* gán 1 trong 7 lớp, không có lớp “other”. Em xử lý 2 cách: (1) Confidence threshold 50% → low-conf hiển thị warning. (2) Predictive entropy cao → OOD signal. Production cần OOD detector riêng (Mahalanobis, Energy score) — em chưa làm, là future work.

Q6: Bao nhiêu false negative MEL?

167 ảnh MEL thật, ensemble nhận đúng 124 → **43 bỏ sót** (recall 0.74). 35 ca nhầm thành NV, 8 ca thành BKL. Threshold tuning với Youden’s J hạ ngưỡng MEL 0.143 → 0.100 đẩy recall 0.74 → 0.83, đổi lại tăng false positive nhẹ.

Q7: Sao không Focal Loss?

Em đã thử, code sẵn trong `losses.py`. Focal Loss không kết hợp Mixup/CutMix mượt vì nhả lại $[0.7, 0.3]$ không phải one-hot. Em chọn Label Smoothing đơn giản hơn, kết hợp Mixup natively, kết quả 0.845 F1 đã đủ tốt.

Q8: ECE bao nhiêu?

EB0: 0.041 → 0.018 sau temperature scaling. Swin cao nhất 0.067 → 0.024. Ensemble các mô hình đã calibrate giảm ECE thêm. Sau temp scaling, xác suất tin cậy được cho clinical decision.

Q9: Bias da trắng → Việt Nam?

Em thừa nhận. HAM10000 chủ yếu Fitzpatrick I-III (Áo/Mỹ). OOD trên PAD-UFES-20 (Brazil, nhiều Fitzpatrick III-IV) cho thấy drop 56 pp — một phần do skin tone shift. Hướng giải: (1) Fine-tune trên data Việt Nam, (2) Augmentation hue/saturation theo Fitzpatrick, (3) Group fairness loss.

Q10: Production cần gì hơn?

(1) CE marking / FDA 510(k). (2) Data in-domain (500-5K ảnh bệnh viện). (3) Open-set detector. (4) UI bác sĩ tích hợp PACS/EHR, audit log. (5) Monitoring sau deploy (data drift, performance). (6) Phân chia trách nhiệm khi sai sót. Em không claim production-ready — là research prototype.

22. Defense kit checklist

22.1. Phần cứng

- Laptop chính + sạc (kiểm tra pin đầy).
- Adapter USB-C / HDMI cho máy chiếu.

- Chuột rời / clicker.
- USB dự phòng chứa: slides VN + EN + thesis + study guide + 5 screenshot demo.
- 1 bản in slides 4-up.

22.2. Software & demo

- **15 phút trước defense:** streamlit run app.py → <http://localhost:8501>.
- Set theme (Dark / Light) menu : → Settings → Theme.
- Upload sẵn 1 ảnh demo, xem Grad-CAM cho cả 4 mô hình → warm-up cache.
- Chuẩn bị 3 ảnh: 1 MEL rõ, 1 NV lành, 1 ca low-confidence để show warning.

22.3. Backup plans

- Streamlit crash → 5 screenshot demo trong slide.
- Máy chiếu không nhận → PDF slides trên USB, mở từ máy phòng.
- Mất Internet → app.py chạy 100% offline.

22.4. 1 tiếng trước

- Test trên máy chiếu thật (nếu cho).
- Nghe lại bản ghi rehearsal cuối.
- Ăn nhẹ (chuối, hạnh nhân).
- Đi WC.
- Điện thoại → máy bay mode.

23. Tóm tắt một trang (in mang theo)

Project tóm tắt

Bài toán: 7-class skin lesion classification, ISIC 2018, 58:1 imbalance.

Pipeline: fine-tune 4 backbone pretrained ImageNet (EB0, RN50, DN121, Swin) + Weighted Sampler + Mixup($\alpha=0.2$) + CutMix($\alpha=1.0$) + Label Smoothing($\epsilon=0.1$) + AdamW + cosine warmup + FP16.

Soft-voting ensemble 4 mô hình $\Rightarrow$:

- 1 seed: **89.49% Acc / 0.845 F1 / 0.980 AUC**
- 5 seeds: **89.93 $\pm$ 0.66% / 0.852 / 0.982**
- McNemar Fisher $p < 10^{-7}$ vs. mọi mô hình đơn.

+ **Metadata fusion** (19-dim: age + sex + localization) $\Rightarrow$:

- Ensemble: **90.49% Acc / 0.873 F1 / 0.984 AUC** (vượt Pacheco 2020).
- Swin + metadata 89.82% — đơn lẻ vượt ensemble chỉ ảnh.

OOD trên PAD-UFES-20: 32.46% (drop 56 pp), AUC per-class 0.61–0.81.

Ablation: Mixup/CutMix quan trọng nhất (-4.51% F1 khi bỏ).

Grad-CAM định lượng: focus_ratio > 0.6 , peak_distance < 0.2 cả 4 mô hình.

Hạn chế: OOD smartphone tẻ, không metadata $\rightarrow$ Việt Nam (bias da), 7 lớp hẹp.

Hướng phát triển: domain adaptation, open-set detection, active learning loop.

Honest contribution: không có technique mới — đóng góp ở tích hợp minh bạch, định lượng Grad-CAM, statistical robustness, OOD honest, vượt nhẹ Pacheco bằng ensemble đa kiến trúc.

Đọc tài liệu này 3 lần trước defense. Nhớ chắc 10 câu Q&A. Thuộc 1-page summary. Bạn sẵn sàng.